

分类号 TP391

密 级

UDC 004.9

编 号

# 中南财经政法大学

硕 士 学 位 论 文

基于时空注意力关联学习的

网络视频热点话题检测

研 究 生 姓 名：刘 诗 宇

指导教师姓名、职称：张 承 德 副 教 授

申 请 者 类 别：非 专 项 计 划

申 请 者 学 习 方 式：全 日 制

学 科 门 类：工 学

专 业 名 称：计 算 机 科 学 与 技 术

研 究 方 向：数 据 挖 掘

入 学 时 间：二〇二一年九月

二〇二四年六月



**Associated Learning with Spatial-Temporal  
Attention for Web Video Hot Topic Detection.**

**2024.06**



# 中南财经政法大学学位论文独创性声明和使用授权声明

## 学位论文独创性声明

本人所呈交的学位论文，是在导师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品。对本文的研究做出重要贡献的个人和集体，均已在文中标明。

本声明的法律后果由本人承担。

论文作者（签名）：

2024 年 6 月

## 学位论文使用授权书

本论文作者完全了解学校关于保存、使用学位论文的管理办法及规定，即学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权中南财经政法大学将本学位论文的全部或部分内容编入有关数据库，也可以采用影印、缩印或扫描等复制手段保存或汇编本学位论文。

注：保密学位论文，在解密后适用于本授权书。

论文作者（签名）：

2024 年 6 月



## 摘要

社交媒体的快速发展，导致网络视频数量飞速增长，成为了用户信息交流的主要载体。然而，当一个热点话题爆发时，用户要花大量时间在各大媒体平台浏览视频信息，然后进行归纳整理后，才能更进一步掌握整个热点话题发生的来龙去脉。但是，一旦遇到不熟悉又难以理解的话题时，整个过程就会变得很困难。因此，基于网络视频的热点话题检测成为了一个研究热点。

如今，网络视频数据正在以跨越不同模态、跨越不同平台和跨数据源的方式呈现，而且随着数据量的急剧增长，数据间的关联信息也日益复杂。此外，多模态数据中的“异构鸿沟”问题使得不同模态之间的相似度难以度量，这是一直制约跨模态热点话题检测效果提升的主要障碍。再者，网络视频中每个视频片段都包含多种模式。在每种模式中，对象的动作可能只出现在特定的空间区域或特定的时间段，能够捕捉到视频片段中具有鉴别性的帧和区域尤为重要，这给网络视频热点话题检测带来了巨大的挑战。

为了解决这些问题，本文提出了一种基于时空注意力关联学习的网络视频热点话题检测方法。它能自动选择具有辨别力的时间片段，并专注于信息丰富的空间区域，从而实现热点话题检测。首先，时间注意力聚焦于与热点话题检测相关的重要关键帧。同时，空间注意力强调帧中的显著区域，从而使模型能够在空间层面上纳入判别特征。然后，挖掘文本结构知识并将其纳入文本语义特征，以丰富稀疏分布文本中的信息。在获得文本和关键帧特征后，自适应地学习文本和视觉特征的权重并将其特征进行融合。最后，通过对比度损失挖掘特征之间的相似性，从而实现热点话题检测。来自某知名视频网站的网络视频数据进行的实验表明，在网络视频热点话题检测方面，使用时间-空间注意力关联学习方法优于现有方法。本文主要工作与创新如下：

(1) 提出了一个新颖的框架，通过特征学习弥合文本语义和视觉语义之间的差距。据我们所知，我们首次尝试通过学习判别特征来探索视觉和文本信息的一致性，并进一步提高网络视频热点话题检测的准确性。

(2) 我们提出了一种新颖的 STA 模型，将空间注意力和时间注意力的判别特征结合起来，通过确保文本特征和视觉特征的准确性，在强调突出区域和判别性关键帧的实现相互强化。

(3) 设计了一种新的注意力分布式关联模型，用于从文本和关键帧中提取多模态特征后，该模型可自适应地学习每种模态的权重，以区分不同模态的影响并提高分类的精度。

**关键词：**热点话题检测；网络视频；时空注意力；跨模态；关联学习





## Abstract

The rapid development of social media has led to a rapid growth in the number of web videos, which has become the main carrier of information exchange among users. However, when a hot topic breaks out, users have to spend a lot of time browsing video information on major media platforms, and then summarize and organize it before they can further grasp the ins and outs of the whole hot topic. However, once they encounter unfamiliar and difficult to understand topics, the whole process becomes difficult. Therefore, hot topic detection based on web video has become a research hotspot.

Nowadays, web video data is being presented in ways that span different modalities, across different platforms, and across data sources, and the correlation information between the data is becoming increasingly complex as the volume of data grows exponentially. In addition, the "heterogeneous gap" problem in multimodal data makes it difficult to measure the similarity between different modalities, which has been a major obstacle to improve the effectiveness of cross-modal hot topic detection. Moreover, each video clip in network video contains multiple modalities. In each mode, the object's action may only appear in a specific spatial region or a specific time period, and it is especially important to capture discriminative frames and regions in the video clips, which poses a great challenge for hot topic detection on web video.

To solve these problems, this paper proposes a associated learning with spatial-temporal attention on web video for hot topic detection method. It automatically selects discriminative time segments and focuses on information-rich spatial regions to achieve hot topic detection. First, temporal attention focuses on important key frames related to hot topic detection. Meanwhile, spatial attention emphasizes salient regions in the frames, thus enabling the model to incorporate discriminative features at the spatial level. Then, text structure knowledge is mined and incorporated into text semantic features to enrich the information in sparsely distributed text. After obtaining text and keyframe features, the weights of text and visual features are adaptively learned and their features are fused. Finally, the similarity between features is mined by contrast loss to realize hot topic detection. Experiments conducted on web video data from a well-known video website show that the association learning method using temporal-spatial attention outperforms existing methods for web video hot topic detection. The main work and innovations of this paper are as follows:

(1) A novel framework is proposed to bridge the gap between textual and visual semantics through feature learning. To the best of our knowledge, we make the first attempt to explore the consistency of visual and textual information by learning discriminative features, and further improve the the accuracy of hot topics detection for web videos.

(2) A novel STA model is proposed to combine the discriminative features of spatial

and temporal attention, which achieves mutual reinforcement in emphasizing salient regions and discriminative keyframes by ensuring the accuracy of textual and visual features.

(3) A new attention distributed association model is designed to extract multimodal features from terms and key frames, which adaptively learns the fusion weights of each modality to distinguish the impact of different modalities and improve the classification accuracy.

**Key Words:** hot topic detection; web video; spatio-temporal attention; cross-modality; association learning

## 目 录

|                                |    |
|--------------------------------|----|
| 第一章 绪论.....                    | 1  |
| 第一节 研究背景 .....                 | 1  |
| 第二节 研究目的和意义 .....              | 2  |
| 一、研究目的 .....                   | 2  |
| 二、理论意义 .....                   | 3  |
| 三、现实意义 .....                   | 3  |
| 第三节 国内外研究现状 .....              | 4  |
| 一、话题检测与跟踪 .....                | 4  |
| 二、特征表示 .....                   | 5  |
| 三、基于视觉注意力的方法 .....             | 7  |
| 第四节 研究思路及创新点 .....             | 8  |
| 第五节 论文组织结构 .....               | 10 |
| 第二章 相关概念和技术介绍.....             | 12 |
| 第一节 相关概念 .....                 | 12 |
| 一、话题 .....                     | 12 |
| 二、镜头 .....                     | 12 |
| 三、关键帧 .....                    | 12 |
| 四、语义 .....                     | 12 |
| 第二节 相关技术介绍 .....               | 12 |
| 一、注意力机制 .....                  | 12 |
| 二、文本特征提取 .....                 | 16 |
| 三、视觉特征提取 .....                 | 17 |
| 本章小结 .....                     | 18 |
| 第三章 基于时空注意力关联学习的跨模态话题检测框架..... | 20 |
| 第一节 数据预处理 .....                | 20 |

|                            |           |
|----------------------------|-----------|
| 一、文本信息预处理 .....            | 20        |
| 二、视觉信息预处理 .....            | 21        |
| 第二节 构建时空注意力网络 .....        | 22        |
| 一、连接网络 .....               | 22        |
| 二、空间级注意力 .....             | 23        |
| 三、时间级注意力 .....             | 24        |
| 第三节 文本特征提取 .....           | 25        |
| 第四节 构建关联学习网络 .....         | 27        |
| 一、自适应加权学习 .....            | 27        |
| 二、模态融合 .....               | 28        |
| 三、对比学习 .....               | 30        |
| 第五节 热点话题检测 .....           | 31        |
| 本章小结 .....                 | 32        |
| <b>第四章 实验设计与结果分析 .....</b> | <b>33</b> |
| 第一节 实验设置 .....             | 33        |
| 一、实验环境 .....               | 33        |
| 二、实验数据 .....               | 33        |
| 三、实验参数设置 .....             | 36        |
| 第二节 评价指标及对比模型 .....        | 36        |
| 一、评价指标 .....               | 36        |
| 二、对比模型介绍 .....             | 36        |
| 第三节 实验结果分析 .....           | 37        |
| 一、对比实验分析 .....             | 37        |
| 二、消融实验分析 .....             | 41        |
| 三、示例分析 .....               | 42        |
| 本章小结 .....                 | 42        |
| <b>第五章 总结与展望 .....</b>     | <b>43</b> |
| 第一节 本文总结 .....             | 43        |
| 第二节 未来展望 .....             | 44        |

|                |    |
|----------------|----|
| 参考文献 .....     | 45 |
| 在读期间科研成果 ..... | 53 |
| 致谢 .....       | 54 |



# 第一章 绪论

## 第一节 研究背景

随着互联网的快速发展,网络视频的普及使得人与人之间的互动和联系变得更加频繁和容易。作为视频创作者来说,人们可以随时随地在网络发布自己拍摄的视频,制作视频的成本低且耗时短。对于受众群体来说,视频对比于传统的单一媒体而言,视频拥有较丰富的表现形式,更能吸引人眼球。例如,国内各大视频平台抖音、小红书、视频号等,已经成为了人们心目中传播信息的主流形式。到 2022 年 12 月为止,中国的短视频用户数量已经超过了十亿,其使用比例高达 94.8%,这表明了网络用户对于数字视频内容的喜好程度正在以指数级别的速度增长。

在社交媒体中,当一个话题备受广大群体关注时,一方面,大量不成体系的网络视频会快速被用户上传到各大媒体平台。另一方面,每个创作者所看待热点话题的角度不同,创作者会对这些视频进行二次加工剪辑并结合自己的观点再次上传,有些人会故意制造噱头,为了博取流量来打上和这个热点话题不相关的标题标签,甚至有人想趁此机会制造舆论来博取用户眼球。最终会导致用户难以在搜索了众多网络视频中了解整个热点话题的发展脉络,在众多碎片化、混乱的信息中迷失了方向。对于一些突然爆发的负面热门话题,如果大众无法迅速掌握其全貌,他们将会依赖他们收集到的一些视频信息来做出判断与预测,从而引起负面舆论迅速扩散。




图 1-1 用户检索“COVID-19”时返回的结果

然而,对于普通的用户来说,他们通常都是一步一步地进行检索和浏览,不能从海量的视频中找到有用的内容。当使用者要查询某个热点话题时,通常会将此话题的关键字输入到首页搜索栏。从图 1-1 可以看出,如果用户想了解“COVID-19”这个话题,他会在某知名视频网站进行检索,得到的是数千乃至数万条的大量视频,这些

视频包含了和该话题不相关的,或是被不断地重复播放的视频。对使用者而言,他们必须不断地浏览许多视频,才能理解这一话题的全部进展。但在现实生活中,人们都是用一些比较零散且碎片的时间去刷短视频,这样会导致用户对这一话题不了解且获取信息片面化。对于社会来说,官方媒体平台响应用户的时间慢且较为滞后,如果用户为了博取流量发布了一些不实虚假言论,将会给社会造成舆论压力,很容易影响网络风气和社会的安定。本文所研究的网络视频热点话题检测到可以帮助到普通用户了解整个热点话题的来龙去脉<sup>[1]</sup>。

网络视频是一种融合了多种模式、信息丰富的媒体形式。以图 1-2 中的帧模式为例,一个动作(如“踢足球”)的焦点可能集中在感兴趣的空间区域(黄框),而不是整个帧。在时间序列的不同帧中,视频中每个帧的贡献会有所不同,红框表示图中识别出的关键帧。由于关键帧中包含的对象或动作可能出现在空间区域或者特定的时间段,导致难以捕捉到鉴别性的关键帧和显著区域。因此,网络视频热门话题检测是一项颇具挑战性的任务。



图 1-2 空间和时间注意力在“踢足球”类别的视频序列例子

为了解决这一问题,本文提出了一种基于时空注意力关联学习的网络视频话题检测方法。它能自动选择具有辨别力的时间片段,并专注于信息丰富的空间区域,从而实现热点话题检测。联合使用时空注意力,可以直接捕捉到与热点话题相关的关键帧和区域。然后通过跨模态关联学习探索文本与视觉信息在语义上的关联性,从而找出与搜索的热点话题紧密相关的网络视频。

## 第二节 研究目的和意义

### 一、研究目的

互联网的快速发展使整个时代成为了一个“信息爆炸”的社会,对于如今社交媒体都会存在的视频信息过载的现象,跨模态网络视频热点话题检测研究的目的是从数量庞大、信息碎片化且噪声多的网络视频中帮助用户快速捕捉到与热点话题相关的信息,提高了用户获取信息的速度<sup>[2]</sup>,进一步让用户对整个热点话题有一个较全面的了解、清楚整个话题的发展过程,这样也有助于防止社会舆论的滋生。本项目拟从识别辨别性关键帧及相关区域入手,挖掘视觉和文字之间的内在联系,提高网络视频中的热点话题检测的性能。在视频网站中,通过输入关键字,呈现出与热点话题紧密相关的视频内容,有助于用户把握到整体热点话题发生的始末,从而对热点话题进行更为全面、



客观的认识。

## 二、理论意义

(1) 在 2017 年,《新一代人工智能发展规划》由国务院发布,明确指出需要解决一些关键技术难题,例如跨模态感知计算。本项目在诸多跨模态关联理解和知识挖掘等核心领域实现了重大突破,例如推理,演变以及应用<sup>[3]</sup>。在线短视频融合了音频、文字、图片等多种不同形式的信息,而不同的模态对热点话题的影响力大小给研究带来了很大的挑战性。随着互联网的飞速发展,互联网上各式各样信息也越来越多,例如:用户的点赞,评论,转发,浏览时长等。如何实现跨模态信息的高效融合,是实现人工智能技术发展的关键。

(2) 另外,本课题也适用于新闻学,人工智能,传播学等;本课题是一项以信息技术与管理为核心的学科之间的交叉与渗透,是一项跨学科的探索性研究<sup>[4]</sup>。本研究基于跨模态信息融合方法,为网络舆情与网络安全治理提供了新的思路。本研究还有望为互联网上的跨模态网络视频热点话题检测开辟一条新途径。

## 三、现实意义

中共十九届四中全会提出,要将“完善和保持正确的民意导向”纳入到提高我国政府管理水平的工作之中。在中国步入有中国特色的社会主义新时期以来,中国的经济迅速发展,城镇化速度显著提高。与此同时,我们已经步入了一个更加危险的社会,不安全的新兴风险因子显著增多,各类突发事件不断发生,例如贵州森林火灾和昆明恐怖袭击事件。在互联网快速发展的时代,用户获取信息的主流方式是通过浏览网络视频,这与传统获取信息的渠道截然不同,每一个人都可以成为传播信息“第一来源”。现在很多热点话题可以通过网络的迅速传播进入大众视野,成为用户和媒体之间的讨论焦点,很多话题可以在较短的时间内发展为舆情<sup>[5]</sup>。当一个热点话题被公众广泛关注时,监管部分如果可以较快地响应和梳理整个热点话题的发生、发展脉络,及时向公众告知话题的详细信息,发现对社会安全有影响的不实言论信息及时删除,这样可以将初期的舆论风险拒之门外。网络热点话题的迅速扩散对政府的管理和治理技能提出了更高的标准,然而,提升网络视频热点话题的监测效果是减少网络舆论风险和优化舆论信息监测的有效方法之一。

对于大量的网络视频,随处可见的创作者、加工者、各式各样的传播信息途径,想要精准快速了解到热点话题的发展过程对普通用户来讲是一件困难的事。对使用者来说,提升热点话题的检测能力,不但可以让用户迅速地获得有用的资讯,也可以让使用者更快地把握话题的来龙去脉,进而对热点话题有一个完整、合理的认识。在此基础上,本文提出的模型及研究成果将为监控系统提供更好的服务,同时还可以方便对大量的视频进行管理。

### 第三节 国内外研究现状

本节首先将会从话题检测与跟踪、特征表示和基于视觉注意力的方法这三个方面对国内外的相关研究文献进行系统的总结,然后会梳理出目前这些方面研究的不足以及指出对应的解决方案,最后表明本文拟解决的问题和研究重点。

#### 一、话题检测与跟踪

话题检测和跟踪(TDT)任务<sup>[6][7]</sup>自1996年以来一直在进行前瞻性探索。它要求学者们将新闻媒体集合整理成与同一现实世界热点相关的新闻集群。它还旨在实现将这些热点话题组织成主题<sup>[8]</sup>。美国 DARPA 最初提出的一项研究项目就是话题检测与跟踪,这项任务利用计算机技术,从海量数据中提取有价值的信息,形成相应的话题,并且会持续追踪其后续的发展过程<sup>[9]</sup>。主题检测和检查与自然语言处理技术(包括信息检索、信息挖掘和信息提取)有相似之处。此外,它们主要针对具有突发性和连续性模式的新闻语料,因此,它成为了信息处理方面越来越热门的研究领域。

早期的主题检测方法主要处理长文本文档,如新闻、博客等。传统的主题建模算法 LDA<sup>[10]</sup>和 PLSA<sup>[11]</sup>模型都是基于词共现的长文本主题建模算法。参考文献<sup>[12]</sup>提出了一种去除冗余的策略,直接探索两种没有特定边界的模糊语义-文本和分离矩阵。参考文献<sup>[13]</sup>使用 Latent Dirichlet Allocation (LDA) 主题建模,从主题分析的角度对模糊研究领域进行宏观理解。由于现在的网络视频会呈现一些短小的文本信息,短小的文本表征存在稀疏性。为了理解短文本信息,通常可以找到与主题相关的长文本作为挖掘目标短文本信息的辅助数据。参考文献<sup>[14]</sup>引入一种以图的形式呈现的创新性文件展现技巧,它把每份文件拆分成不同的语义单元,并建立这些语义单元之间的关系。GloVe<sup>[15]</sup>在计算效率和简便性方面表现出色。参考文献<sup>[16]</sup>从辅助长文本数据迁移学习到短文本信息聚类的新方法。参考文献<sup>[17]</sup>利用外部知识来增强数据的相关性,并利用主题建模来解决大规模文本集合中的稀疏性问题。这些方法可以通过分析短文本来检测主题,但没有语义分析。对于视觉信息,参考文献<sup>[18]</sup>提出了一种基于注意力机制的新算法,用于视频表示和分类。这种方法能快速预测视频帧中的语义突出对象,并提取局部和全局特征,以促进话题检测的效果。参考文献<sup>[19]</sup>能够从不同的数据源中检测热点话题,并提取这些话题的相应情感。这些方法主要关注单个模态,往往会忽略跨模态之间的关系。

对于视频和图像等多模态信息,早期主要通过检测视觉特征间的相似度来将原有的图片或者视频归类到不同的话题。文献<sup>[20]</sup>提出了一种基于注意力的视频表示和分类算法,通过注意力机制快速预测视频帧的语义显著性对象,然后利用线性支持向量机来进行分类,因此,挖掘视觉特征之间的相似性在热点话题检测中起着重要作用,但由于网络视频后期会经过很多二次剪辑和编辑,再加上每个视频的录制角度、光照场景都不同,导致同一场景的视觉特征形成了较大的差异,这对话题检测的效果产生

了极大的影响。目前的方法主要是利用多模态数据的相关性信息进行问题的探索。基于近似关键帧的框架可有效整合空间和时间数据<sup>[21]</sup>。通过使用提取的局部特征，可以捕捉到网络视频的主要内容并消除噪声，然后使用这些特征来表示每个视频片段。利用深度学习<sup>[22]</sup>，通过图像理解来丰富短文信息，并通过改进的 LDA 来优化有效的图像词汇。密集嵌套注意力网络（DNA-Net）<sup>[23]</sup>提出了密集嵌套交互模块（DNIM），以实现高层和低层特征之间的渐进交互。用于人脸识别分类的卷积神经网络和图注意力网络（WFCG）提出了加权特征融合方法<sup>[24]</sup>。研究跨媒体数据之间的相关性<sup>[25]</sup>，探索不同模态之间的语义关联。通过融合文本和视觉信息<sup>[26]</sup>，使用 CNN 和 BPSO 方法将社交媒体帖子分为不同类别。此外，随着 NDK<sup>[27]</sup>和 NDS<sup>[28]</sup>使用越来越多，许多工作都是通过计算 NDK（NDS）和事件之间的相似性来完成的。

上述方法可以有效提高话题分类的性能。然而，跨模态数据的异质性给热点话题的检测带来了挑战。通过扩展基于异构网络的 PageRank 算法<sup>[29]</sup>，提出了一种与商业相关的热点话题检测方法。参考文献<sup>[30]</sup>引入一种以注意力图结构为基础的网络视频热点话题检测新方法，这个方法能够生成新的邻接矩阵，同时也能够重构节点之间的连通性。参考文献<sup>[31]</sup>结合 NDK 引发的共现和重复特征轨迹的视觉近似，计算 NDK 与事件之间的相似度。受参考文献<sup>[32]</sup>的启发，本文将文本与关键帧之间的互补性作为一个重要因素。我们计划通过空间层面的注意力来识别帧内的重要区域，并通过时间层面的关注来区分包含独特信息的帧。这样就能同时对两种模态的权重进行动态学习，从而提高话题检测的效果。

## 二、特征表示

### （一）基于手工创建特征的方法

用于热点话题检测的手工特征可分为三个部分：低级、中级和高级特征。局部信息区域或三维体积由捕捉视觉模式的低级特征描述。多模态视频序列和文本特征通过一组共享语义中心进行聚合<sup>[33]</sup>，从而计算同一中心内视频和文本特征之间的相似性。参考文献<sup>[34]</sup>建议使用相似的相邻样本衍生特征作为锚，以生成更具适应性和辨别力的目标。在各种低层特征方法中，Laptev 等人<sup>[35]</sup>将空间兴趣点的概念扩展到了时空领域。由此产生的特征经常能捕捉到有趣的话题，并被用于创建视频数据的简明表示，利用 HOG<sup>[36]</sup>描述符捕捉静态表面信息。此外，还利用 HOF<sup>[37]</sup>和运动边界直方图描述符收集局部运动数据。Wang 等人<sup>[38]</sup>使用 SURF 描述符和密集光流来匹配帧间的特征点，利用 RANSAC 对这些匹配点进行稳健的同源性估算，构成了一种 HOG、HOF、MBH 结合的轨迹有效视频表示法。Xian 等人<sup>[39]</sup>系统地评估了用于检测监控事件（SED）的各种低级特征，低级特征被聚合为向量来表示每个视频片段。此外，研究人员还利用中层和高层特征来构建视频表征。在各种中层特征方法中，Wang 等人<sup>[40]</sup>引入了运动原子（motion atom）和运动短语（motion phrase）来表示视频中的复杂动作，动作原子被代表为动作的原子部分，它捕捉到了短视频中具有高辨别力和具有代表性的有

效动作短语。Liu 等人<sup>[41]</sup>使用一组介入字符来表示视频中的人类行为，这些概念可以手动指定，也可以在训练过程中学习。Wang 等人<sup>[42]</sup>通过挖掘具有连贯外观和运动特征的时空部分来构建中层视频表示，设计了一种数据驱动方法，从训练视频中学习运动特征。考虑到视频中的单个动作和交互动作，Fradì 等人<sup>[43]</sup>建议从紧凑的局部表征中提取丰富的中层视觉描述符，并利用它们来编码语义信息。Shah 等人<sup>[44]</sup>将低级事件之间的关系构建成一个图，将低级事件视为存在/不存在的隐藏变量，并通过 SVM 学习判别模型。Sun 等人<sup>[45]</sup>使用隐马尔可夫模型捕捉视频概念之间的时间转换，并通过费雪向量将视频编码为固定长度的向量。Motionlet 等人<sup>[46]</sup>通过识别表现出一致外观和运动特征的时空组件来构建中层视频表示。因此，可以在可重复性和鉴别力之间取得平衡。Zhang 等人<sup>[47]</sup>通过学习高层特征的结构化轨迹来提取连贯的运动特征，他们提出了一种人群运动行为的高级表示法来描述人群行为的语义特征。

## （二）基于深度特征的方法

深度学习已经证明了其学习强大特征的能力。随着深度网络的使用，视频分类取得了重大进展<sup>[48]</sup>，它可以学习更多的判别特征<sup>[49]</sup>。我们根据网络设计将基于深度特征的方法分为四类：时空网络、多流网络、深度生成网络和时空一致性网络。表 1-1 详细总结了这四类方法。

表 1-1 基于深度特征方法的汇总

| 分类      | 总结                                  |
|---------|-------------------------------------|
| 时空注意力网络 | 从时间和空间两个维度提取特征                      |
| 多流网络    | 采用多个深度网络来收集各种模型的输入，并将其融合以获得最终的预测结果。 |
| 深度生成网络  | 利用一个无监督生成模型来学习时间序列特征                |
| 时间一致性网络 | 该网络通过利用时间顺序来获取视觉表征，它假定视频帧是与背景和动态相关  |

基于时空注意力网络，Ji 等人<sup>[50]</sup>利用时空注意力网络构建了一种 3D CNN 模型，该模型在动作识别方面发挥了重要作用。他们采用三维卷积神经网络，从空间和事件两个角度提取特征，成功捕获了多个相邻帧的编码运动信息，这为视频的时空信息学习提供了有效的支持。Ng 等人<sup>[51]</sup>提出了两种能处理长视频的方法。第一种是挖掘了各种卷积时空特征池里的架构，调整 CNN 在这一任务中的设计选择。第二种方法是将一个视频构建成一个有序的帧序列，然后通过递归神经网络将长短期记忆（LSTM）单元与底层 CNN 的输出相结合，利用最大池化策略和长短时记忆网络（LSTM）将视频中长时段的图像信息结合起来来聚合空间和时间信息。因此，聚合空间内核时间信息能更好地进行视频分类。Wang 等人<sup>[52]</sup>提出了一种用于视频动作识别的时间分割网络，这是一种视频级框架，它结合了稀疏时空采样策略和视频级监督，能够高效学习到视频中的工作信息，具有对长期时间结构建模的能力。基于多流网络，Simonyan

和 Zisserman<sup>[53]</sup>提出了一种用于视频分类的双流 CNN 架构，它由两个将帧和光流作为输入的 CNN 组成。除了帧和光流作为多流网络的输入之外，Wu 等人<sup>[54]</sup>还利用音频信号来进一步提高视频分类性能，它能够对视频中的静态空间信息、短期运动以及长期事件线索来进行建模。基于深度生成网络的方法<sup>[55][56]</sup>采用生成模型，以无监督方式从时间序列中学习特征。Yan 等人<sup>[55]</sup>引入了一种名为 Dynencoder 的深度自动编码器来捕捉视频动态，该编码器从原始图片输入生成隐藏状态，然后通过编码器适当构建堆叠策略，通过分层预训练和联合微调两个阶段来进行最终的训练。Srivastava 等人<sup>[56]</sup>提出了一种 LSTM 的自动化编码器，它能将输入信息转换成一种固定的长度形式，然后利用一种或多种 LSTM 解码器来完成解码，从而实现对未来序列的预测和其他相关工作。基于时间一致性网络，Wang 等人<sup>[57]</sup>设计了一种连体网络，将有关动作或事件的视频帧分成前提条件集和效果集，然后通过学习将动作建模为高层特征空间上的一种变换。Bruna 等人<sup>[58]</sup>利用相邻视频帧包含语义像信息，从无标记视频数据中在慢速特征学习和度量学习之间构建了联系，利用这些联系，定义了一种可用于自动选择超参数的标准。

这些研究主要侧重于独立学习单个模态的特征表征。由于文本和关键帧信息之间具有天然的互补性<sup>[59]</sup>，因此，它们应该相互协作学习，互相促进。以“俄罗斯世界杯”这个话题为例，足球、球员、踢球等关键帧信息有助于与其他话题与足球运动无关的类别区分开来，而文本信息可以起到一个补充作用。为了利用文本与关键帧之间的强互补性，本文探索性地提出了一种跨模态关联学习方法，自适应地为每种模态分配不同的权重，并学习判别特征，以改进其表征学习。

### 三、基于视觉注意力的方法

#### （一）空间级注意力

应根据帧区域对分类性能的贡献，为帧区域分配不同级别的注意力。最近，一些学者将空间级注意力模型纳入了这一研究。Mnih 等人<sup>[60]</sup>提出了一种新颖的递归神经网络模型，它能够自适应地选择一些位置或者一系列区域，从图像或者视频中提取有效信息，用该方法可自适应地选择区域序列，并只处理所选的高分辨率区域。Greene 等人<sup>[61]</sup>提出了一个新颖实用的框架，将单词嵌入向量通过两层注意力来解释整个决策过程，从而获得主题的权重分布。Zhang 等人<sup>[62]</sup>提出了一种有效的空间注意力与特征模仿（SANM）的端到端头部检测器，它可以通过注意力机制和特征模仿的方法获取更好的特征并增强其分类能力。Zhu 等人<sup>[63]</sup>设计了一个空间注意力模块，用于自适应地选择空间信息，即抑制无用像素或者不同类的像素，强调与中心像素同类别的像素或者像素中心周围对分类有用的像素。Sun 等人<sup>[64]</sup>以空间注意力网络和关系模块增强头部网络结合，生成空间注意力图，然后将注意力图与分类分支的对象得分相乘，结合外观和几何特征来进行物物体识别。Xin 等人<sup>[65]</sup>结合扩张残差网络、挤压激励（SE）模块和空间注意力（SA）模块，提出了一种新颖的分类网络。其中 SA 模块能较好地

利用图像中地长期依赖关系, SE 模块可以利用全局信息抑制不相关和无用特征, 增强有用信息特征。Karpathy 等人<sup>[66]</sup>设计了一种多分辨率 CNN, 将注意力固定在画面中心, 通过多种方法来扩展 CNN 在时域中的连接性, 以利用局部时空信息, 将多分辨率、有凹槽的架构作为加快训练速度的一种方法。然而, 突出区域并不总是位于图像中心。空间变换器在 CNN 各层之间添加了软注意力机制。这使得神经网络能够主动对特征图进行空间变换。不过, 他们不是通过最大的关注层进行位置加权, 而是将仿射变换应用于网络的多个层。利用图卷积捕捉空间模式, 基于注意力的时空图卷积网络<sup>[67]</sup>可以有效捕捉数据中的动态相关性。

## (二) 时间层面的注意力

时间注意力用于强调辨别性关键帧, 这些帧在生成视频语义表征方面发挥着更重要的作用。寻找辨别帧<sup>[68]</sup>的模型基于相邻帧之间的动态关系。他们通过局部运动特征的分布来表示判别帧。然而, 阈值是固定的, 其效果并不稳定。通过自动识别视频中最具区分性的时间子序列, 可以学习到不断变化的外观和运动序列。基于多通道时间注意力的网络<sup>[69]</sup>, 可将每个时间序列的位置直接连接到序列的局部区域, 以避免时间信息的丢失。N.Denison 等人<sup>[70]</sup>建立了一个视觉时间注意力的动态归一化模型, 在特定时间点上对视觉信息进行优先排序, 然后对一系列由不同时间间隔分开的两个物体进行时间注意力。Wharton 等人<sup>[71]</sup>利用时空注意力对细微变化进行建模, 在可训练的网络中引入粗时空分支, 目的是通过聚焦视频中的特定部分, 捕捉到更高层次的时间关系。Fan 等人<sup>[72]</sup>构建了一个端到端的深度学习框架, 该框架利用时间注意力机制, 对历史数据进行了优质的捕获, 从而帮助预测未来的潜在模型。此外, 它还能够产生多个未来水平线的量化预测。Sun 等人<sup>[73]</sup>通过为时间序列特征向量分配不同的权重来描述特征的贡献程度, 然后对每个语义维度进行细粒度特征融合, 从而有效学习各个模态之间的语义差异信息。Liu 等人<sup>[74]</sup>基于增强帧选择技术选择辨别帧。他们使用了一种有监督的金字塔运动特征, 该特征结合了光流和生物特征来检测兴趣点, 从视频序列中的每一帧中提取运动信息, 然后通过集成学习 (AdaBoost) 算法从大量的特征库中挑选出最具有辨别性的关键帧。

然而, 上述研究分别学习了空间级注意力或时间级注意力, 忽略了它们之间的共存关系。在本文中, 我们提出了一种空间-时间注意力模型, 它能联合学习空间级注意力和时间级注意力, 并增强两者的能力, 从而提高热点话题检测的准确性。

## 第四节 研究思路及创新点

最近, 由于深度学习在特征学习方面的强大功能, 它已被广泛应用于热点话题检测中。首先, 基于手工特征的方法<sup>[75]</sup>侧重于检测时空兴趣点, 然后通过局部表示或局部特征进一步编码为向量表示来描述这些兴趣点。其次, 卷积神经网络 (CNN) 被广泛应用于视频表征学习的深度模型中<sup>[76]</sup>, 作为学习视觉外观的一种手段。此外, 循环

神经网络（RNN）也被用于视频中的时间动态建模。现有的方法一般侧重于空间外观和时间动态，但没有充分利用联合考虑空间-时间依赖性的注意机制。因此，有必要对它们进行协作学习，以相互促进。图 1-3 是“俄罗斯世界杯”视频序列的空间-时间注意力示例，图 1-3（A）是原始视频序列。图 1-3（B）中的热图显示了空间注意力，并更加强调包含“球员”和“踢球”的区域。此外，红色矩形中尺寸较大的帧显示了时间注意力，这对区分“踢”的语义表征非常有效。为了实现空间级注意力，必须对具有不同显著性的帧中的显著区域给予关注。每一帧对视频识别的贡献都是不平等的，如果来实现时间级注意力，则应更多地关注包含更多分辨信息的帧。因此可以推断，通过联合使用 STA，可以直接捕捉到与热点话题相关的关键帧和区域。然后通过跨模态关联学习来研究文本和视觉信息在语义上的关联性，从而找出与搜索的热门话题紧密相关的网络视频。




图 1-3 “俄罗斯世界杯”视频序列的空间-时间注意力的例子

然而，不同的时间片段对原始视频中的动作识别有不同的贡献，有些片段对分类没有影响，而有些片段则会误导动作分类器。空间-时间注意力捕捉到的判别关键帧可能与新闻转场或主持人播报等热点话题无关，从而导致视觉语义特征的获取不准确。因此，本文提出了一种新颖的时空注意力关联学习方法。如图 1-4 所示，该方法首先应用时空注意力，以此来突出分辨框架内的重要区域。随后自适应学习文本信息和视觉信息的权重，利用它们的强互补性来提高分类的准确性。




图 1-4 本文方法的设计思路

本文的主要创新点和贡献总结如下：

(1) 提出了一个新颖的框架，通过特征学习弥合文本语义和视觉语义之间的差距。据我们所知，我们首次尝试通过学习判别特征来探索视觉和文本信息的一致性，并进一步提高网络视频热点话题检测的准确性。

(2) 我们提出了一种新颖的 STA 模型，将空间注意力和时间注意力的辨别特征结合起来，通过确保文本特征和视觉特征的准确性，在强调突出区域和辨别性关键帧时实现相互强化。

(3) 设计了一种新的注意力分布式关联模型，用于从文本和关键帧中提取多模态特征，该模型可自适应地学习每种模态的融合权重，以区分不同模态的影响并提高分类精度。

## 第五节 论文组织结构

本文的内容总共包括五个章节，组织结构如图 1-5 所示。






图 1-5 本文组织架构图

第一章 绪论。本章将主要介绍研究生背景、研究目的和意义、对应研究方法的国内外研究现状以及当前研究所面临的挑战，最后引出要解决这些问题的本文的研究思路和创新点。

第二章 相关理论和技术介绍。本章将对话题、镜头、关键帧、语义进行详细阐述；在此基础上，分别介绍了注意力机制的原理、时间空间注意力经典模型；其次，详细介绍了文本特征提取和视觉特征提取的相关技术。

第三章 基于时空注意力关联学习的跨模态话题检测框架。在这一章节里，我们首要针对网络视频的文本内容以及视觉信息做了预处理，然后利用第二章提供的技术方法，获取了跨模态的数据特征。然后搭建了时空注意力网络和关联学习网络，最后在对比学习的约束下对特征分类挖掘出热点话题。

第四章 实验设计及结果分析。本文选择了 23 个在知名视频网站上的热门话题的视频和文本信息，对第三章所提出的方法进行了大规模的实验，利用既有的经典模型进行了对比分析和消融实验，最终还以一个详细的案例来解读结果，证实了我们所提出的方法可以显著增强网络视频的挖掘成效，而且其效果优于现有的方法。

第五章 总结与展望。首先，本章对本文所提出的研究方法、主要工作和成果进行了系统的总结，接着指出了本研究中仍有的缺陷和需要改进的地方，最后，对未来的研究进行了展望。

## 第二章 相关概念和技术介绍

### 第一节 相关概念

#### 一、话题

话题(Topic)是由一系列具有重大意义的事件组成<sup>[77]</sup>, 其中一般含有一个或多个与之有关联的种子时间。比如“俄罗斯世界杯开幕式”、“法国队击败克罗地亚队”等都属于“俄罗斯世界杯”这一话题。“热点话题”是指短时间内能够使公众关注到的一系列事件, 具有以下特点: (1)被各大内体重复频繁报道宣传, 如“新冠疫情”; (2)用户对该话题格外关注且具有明显的事件聚集性。

#### 二、镜头

一连串的画面是由摄像机在连续拍摄中积累起来的, 这就是所谓的镜头(shot)。一段影片由多个摄像机构建, 挑选出最能体现话题的帧作为关键帧。因此, 一个包含众多镜头的视频也能通过一系列关键帧进行展现。

#### 三、关键帧

一段视频通常由多个镜头构建的画面信息, 其中, 摄影机是从各种固定角度捕捉的画面内容, 也可以被定义为位于两个剪接点之间的视频片段。因此, 一段连贯的视频由许多镜头构成, 而关键帧则是描绘每一镜头的核心重要性的视觉信息。

#### 四、语义

语义(semantic)是指数据所表示的意义。数据以各种形式呈现, 包含视频、文本、图像、音频等。数据本身没有意义, 赋予了含义之后才能够被使用, 这样数据就会转变为所谓的信息<sup>[78]</sup>。当计算机了解了数据的语义之后, 就能通过语义来捕捉到跨模态之间数据之间的联系。有两种主要的语义类型: 高级语义与低级语义。前者主要描述了宏观的特性, 更适应于人类的理解, 后者则主要描述了微观的特性, 例如形状、颜色等, 这些将更加适应于电脑的理解。通常, 文字信息传递的语义属于高级语义, 具有宏观的特点, 然而, 视觉语义更为详尽和精确, 属于低级语义。

### 第二节 相关技术介绍

#### 一、注意力机制

##### (一) 原理

注意力机制能够模仿大脑处理信息的方式, 每次观察一个图像, 我们都会把目光集中在特定的地方, 并且不公正地去审视观察的内容, 根据专注于特定的细节, 从而掌握整体的情况。通过注意力机制, 我们能够在处理信息的过程中有效地分配“注意”资源。在进行热点话题的检测任务时, 对于大量的文字, 注意力机制能够更有效地抓

取文本的核心含义，从而提升热点话题检测的精确度。将注意力机制应用于关键帧提取，可以有效地提取出图像中具有区别性的关键帧以及与话题有关的关键区域。将注意力机制引入到多模态数据的融合中，可以让计算机不再需要对每个模态进行相同的处理。关于注意力机制的主要思路，就是将源序列 $X$ 的每个组成元素视为多个类似的 $\langle key, value \rangle$ 形式的键值对。在目标句子 $Y$ 中，我们必须随机选择一个均衡地赋值给 $Query$ ，然后对 $Query$ 以及源序列中每个 $key$ 都进行权重计算，其计算结果就是对应 $Value$ 的权重系数，最后通过这些系数的加权求和，便可获得注意力的概率分布。其本质思想如公式 2-1 所示：

$$Attention(Query, Source) = \sum_{i=1}^{L_p} Similarity(Query, Key_i, * Value_i) \quad (2-1)$$

其中 $Source$ 就代表源句子 $P$ ， $L_p$ 代表源句子的长度。根据 attention 机制的本质思想，可以将它的运算分为三个步骤。第一步是输入数据，第二步是求出概率分布 $\alpha$ ，第三步是根据概率分布计算输入数据加权求和的平均值，如下图所示：




图 2-1 Attention 机制计算流程图

第一步：输入数据，用 $P = \langle p_1, p_2, \dots \rangle$ ，表示输入信息有 $n$ 个；

第二步：计算概率分布，首先是确定计算每个 $Key$ 与 $Query$ 之间的关联程度，以此来确定所需要的注意力权重，接着利用 softmax 函数对权重标准化。另外的权重归一化方法<sup>[79]</sup>同样适用，常用的相似度计算方法有如下几种。

$$S_{ij} = \text{score}(q_i, k_i) = \begin{cases} q_t^T k_i & \text{点积} \\ q_t^T W k_i & \text{通用} \\ \frac{q_t^T k_i}{\sqrt{d}} & \text{缩放点积} \\ v^T \tanh(W[q; k_i]) & \text{拼接} \\ v^T \tanh([Wq; Uk_i]) & \text{相加} \end{cases} \quad (2-2)$$

其中,  $S_{ij}$  表示注意力模型中的相似性得分,  $W$  和  $U$  则是用于学习的参数矩阵,  $v$  则是代表参数向量。

因为各种计算方法产生的分数  $S_{ij}$  范围不同, 因此需要用 **softmax** 函数将注意力值进行归一化处理, 从而把初始计算数据转换到 0 到 1 之间, 具体的计算公式如下:

$$\alpha_i = \text{softmax}\left(\frac{e^{s(x_i, q)}}{\sum_{j=1}^{L_x} e^{s(x_i, q)}}\right) \quad (2-3)$$

第三步, 对信息进行加权平均。在获取到注意力权重之后, 我们可以通过将各值向量与权重相乘来获取注意分布值, 具体计算公式如下:

$$\text{Attention}(Q, K, V) = \sum_i \alpha_i V_i \quad (2-4)$$

其中,  $Q$  表示查询 *Query*,  $K$  表示键值 *Key*,  $V$  为目标句向量 *Value*, 当我们将句向量与权重的乘积求和时, 注意力权重分布  $\alpha_i$ , 可理解为查询  $Q$  为第  $i$  个信息受到的关注程度, 关注度越高对应的权重越大。

## (二) 空间注意力机制

并非所有的区域在图像中都具有相同的作用, 只有与任务相关的部分才应被重视。例如, 在分类任务的主要部分, 空间注意力模型就是在网络中寻找最关键的地方进行处理。

在最近的几年里, 卷积神经网络在许多领域都实现了显著的进步。卷积核作为卷积神经网络的关键组成部分, 一般被视为在局部感知范围内, 集成了空间层面 (**spatial**) 的数据以及特征层面 (**channel-wise**) 的数据的信息集合。卷积神经网络是由多个卷积层、非线性层以及下采样层组合而成的, 因此, 他们可以在整体的感知范围内抓取图像的特征并对其进行解释。

在 CNN 中, 输出的二维图像有两个维度, 其中一个图片的大小, 也就是长度和宽度, 而另一个则代表着通道。所以, 利用这两个维度进行 **Attention** 的方法被广泛应用。SENet (Squeeze and Excitation Net) [80] 在 2017 年 ImageNet 的分类竞赛中获得了胜利, 其实质就是一个以通道为核心的注意力集中模型。该模型能够根据每个特定的通道的关键性来进行建模, 并且能够根据不同的任务需求来提升或限制这些通道, 具体的工作原理可参见图 2-2。




图 2-2 SENet 原理图

图 2-2 是 SENet 的原理图。对于一个输入  $x$ , 我们设定其特征通道数为  $c_1$ , 然后经过一连串的卷积等常规变换, 可以获得一个特征通道数为  $c_2$  的特征。接下来, 将通

过三个步骤来重新标定之前获得的特征，这与传统的 CNN 有所不同。

首先的步骤是 **Squeeze**，我们根据空间维度对特征进行压缩，把每个二维的特征通道转化为一个实数。这个实数在一定程度上拥有全局的感知范围，同时，其输出的维度与输入的特征通道数量保持一致。该方法描绘了特征通道的全局分布，同时让接近输入的部分能够拥有整体的感知范围，这对于许多工作来说极其重要。

接下来是 **Excitation** 操作，这个过程与循环神经网络的中门机制相似。利用参数  $w$  来为每一个特征通道设定权重，而这些参数  $w$  则被用于明确地构建特征通道之间的关联性。

最后是一个 **Reweigh** 的步骤，我们把 **Excitation** 输出的权重视为经过特征选择后的每个特征通道的重要性，接着通过乘法逐个通道加权到之前的特征上，实现在通道维度上对原始特征的重新定义。

SE 网络能够通过简化 SE 组件的组合形式产生。SE 块同样适合在系统架构内进行各种级别的初级块的直接更新。尽管建立模块的模板具有普遍性，但其在各种深度上的作用能够满足网络的需求。在初级阶段，它已经掌握了以无法预知的方式激活信息特性，以支持共享的基础表达的品质。随着阶段的推进，SE 块的专业性逐渐增强，并且能够以独特的方式对各种输入做出反应。所以，SE 块的特性重新调整的益处能够在全网中得到积累。SE 块的构建相当简洁，能够直接和当前最尖端的系统架构相结合，这些架构的组件能够通过直接替换 SE 模块来增强。

### （三）时间注意力机制

时间关注度被认为是一种灵活的时间选择策略，它能够确定我们应该在什么时候关注，所以它一般被应用在视频处理中。以前的工作经常强调如何捕获短期和长期跨帧特征依赖。RNN 和时间池化或权值学习已被广泛应用于视频表示学习中，以捕获帧间的交互，但这些方法在效率或时态关系建模方面都有局限性。为了克服这些问题，Gehrmann 等人<sup>[81]</sup>提出了一种全局时间表示法（GLTR），以利用视频序列中的多尺度时间线索。GLTR 由用于局部时间上下文学习的空洞时间金字塔（DTP）和用于捕获全局时间交互的时间自注意力模块组成。DTP 采用空洞卷积，空洞率逐渐增加，以覆盖不同的时间范围，然后将各种输出连接起来，以聚合多尺度信息。给定输入的逐帧特征  $F = \{f_1, \dots, f_T\}$ ，DTP 可以写成：

$$\{f_1^{(r)}, \dots, f_t^{(r)}\} = DConv^{(r)}(F) \quad (2-5)$$

$$f'_t = [f_t^{(1)}; \dots; f_t^{(2^{n-1})} \dots; f_t^{(2^{N-1})}] \quad (2-6)$$

其中  $DConv^{(r)}(\cdot)$  表示具有空洞率  $r$  的空洞卷积。自注意力机制采用卷积层，然后通过批归范化和 ReLU 激活，基于输入特征图  $F' = \{f'_1, \dots, f'_T\}$  来生成  $Q \in \mathbb{R}^{d \times T}$ ， $K \in \mathbb{R}^{d \times T}$ ， $V \in \mathbb{R}^{d \times T}$ ，可以写成

$$F_{out} = g(V \cdot Softmax(Q^T K)) + F' \quad (2-7)$$

其中  $g$  表示通过卷积实现的线性映射。

来自相邻帧的短期时间上下文信息有助于区分视觉上相似的区域，而长期时间信息有助于克服遮挡和噪声。GLTR 结合了这两个模块的优点，增强了表示能力并抑制了噪声。它可以整合到任何先进的 CNN 主干网中，学习整个视频的全局描述符。然而，自注意机制具有二次时间复杂性，限制了其应用。

为了高效灵活地捕捉复杂的时间关系，Liu 等人<sup>[82]</sup>提出了一种时间自适应模块（TAM）。它采用自适应核代替自注意力来捕获全局上下文信息，时间复杂度低于 GLTR<sup>[81]</sup>。

TAM 有两个分支，一个局部分支和一个全局分支。给定输入特征图  $X \in \mathbb{R}^{C \times T \times H \times W}$ ，首先将全局空间平均池化 GAP 应用于特征图，以确保 TAM 具有低计算成本。然后，TAM 中的局部分支在整个时间域上使用多个具有 ReLU 非线性的 1D 卷积来生成位置敏感的重要性图，以增强逐帧特征。与局部分支不同，全局分支是位置不变的，并且专注于基于每个通道中的全局时间信息生成通道自适应内核。在局部分支和全局分支的帮助下，TAM 可以捕捉视频中复杂的时间结构，并以较低的计算成本增强每帧特征。由于其灵活性和轻量级设计，TAM 可以添加到任何现有的 2D CNN 中。

## 二、文本特征提取

文字特征提取是一种广泛应用于文字挖掘、信息检索等领域的技术，其主要研究内容是针对某一类大段文本材料，生成具有一定语义的核心关键字<sup>[83]</sup>。该方法与传统的基于文本的关键词有所区别，而是通过算法自动提取出来的。熟练了这种技巧之后，可以对文本进行快速的归类和标记，帮助人们更快地了解文段的内容，而且它还是一种简便有效的方法，对于文字聚类、文字识别等都有着非常重要的意义。

本文采用 Wide & Deep 模型和 Bert 模型来提取文本特征。Wide & Deep 是一种同时考虑浅层模型和深层模型的推荐模型。Wide & Deep 模型的核心思想是将浅层模型（Wide Component）和深层模型（Deep Component）组合起来，以平衡模型的记忆能力和泛化能力。Wide 的功能在于赋予模型更高的“记忆力”。“记忆力”是指模型对于从过去的数据中提取出的事件或特征的“共鸣频率”的掌握程度。通常，如协同过滤和逻辑回归这样的基础模型具备很高的“记忆力”。因为这种模型的构造相对简洁，初始数据通常能够直接作用于推荐结果，也就是说，模型能够直接理解历史数据的分布特性，并借助这些理解来做出推荐。Deep 的核心功能在于赋予模型“泛化”能力。“泛化能力”是指模型传递特征的相关性，同时也是揭示罕见或者从未存在的特殊属性和最终标签相关性的能力。深度学习的神经网络能够多次自我融合各种特征，从而有效地挖掘出数据背后隐藏的规律。即便是极其稀疏的特征值，它们仍然有能力产生相对稳定的推荐概率，这正是传统模型无法实现的“泛化”能力。

wide 与 deep 的组成部分利用它们的输出对数概率的加权总和来进行预测，接着把这些数据导入一个共享的逻辑损失函数进行联合训练。注意到这里的联合训练和集成学习是有区别的。在整体性的学习过程里，各种模型都经过了单独的训练，同时，

它们的预测结果也是在推断阶段进行整合,而非在实际应用阶段进行整合。与此相比,联合训练在进行训练的过程中,会同时考虑 **wide** 和 **deep** 模型,并通过加权的方式调整所有的参数。模型的大小也会受到影响;在集成学习中,由于训练是独立的,所以每个模型的尺寸通常会更大(比如:更多的特征和交叉特征),以便达到一个集成模型的合理精度。相比之下,**wide** 的部分仅需利用微小的跨产品特征转化以弥补深度模型的缺陷,并非完整的模型。通过小规模随机优化,**wide** 和 **deep** 模型的联合训练能够将输出的梯度反向传递到模型的 **wide** 和 **deep** 部分。在试验过程中,我们选择了带有 $L_1$ 正则的 FTRL 算法来进行 **wide** 部分的优化,而 AdaGrad 则被选为 **deep** 部分的优化器。

**Bert** 是一个利用 **Transformer** 进行特征提炼的深层次双向预训练语言理解模式。**Bert** 作为一个预先训练的模型,采用了双向 **Transformer**,借助海量的数据进行语言表征模型的训练。它被视为一个普遍模型,可以通过进行微小的调整以满足各种下游任务,如分类、回归、机器翻译和问答系统等。

**Bert** 框架分为两个阶段:预训练和微调。在预训练阶段,模型将依照各种初始训练任务,对未标注的数据进行训练。在进行微调的过程中,我们首先利用预训练参数来启动 **BERT** 模型,接着利用下游任务的标记信息来对所有的参数进行微调。虽然每一项下游任务都采用了相同的预训练参数来启动微调模型,但是每一个任务都具备自己的特定微调模型。要进行深度双向表达的训练,我们只需要随机地屏蔽某些比例的输入标记,接着预测这些被屏蔽掉的标记。在此状态时,与掩码标签匹配的最后隐藏向量将被加载至词汇表的最终输出值中,如同在常规 **LM** 里那般。尽管这种方式能够产生双向的预训练模型,但其缺陷在于预训练和微调之间存在不匹配,因为在微调阶段不会有[MASK]标记。为了解决这个问题,并不总是用真实的[MASK]标记来替代“屏蔽”一词。数据生成器在训练过程中,会随机挑选 15%的标记位置来进行预测。若第  $i$  个指示符被挑选出来,将有 80%的可能性使用以下的指示符代替第  $i$  个指示符:(1) [MASK]指示符。(2) 在 10%的条件下,我们使用了随机标注。(3) 在 10%的条件下,使用第  $i$  个保持恒定的标志。针对各个任务,我们仅需要把特定的任务的输入与输出输入 **BERT**,然后在端到端进行全面的参数修改。在输入端,预处理的句子与句子之间的关系如下:(1) 叙述过程中的句子匹配;(2) 在推理过程中的预测-事实关联性;(3) 在回答问题时,需要考虑的是与段落的匹配性。(4) 在文档分类或序列标记中的衰减型文档。在输出部分,标记被派送到标记级任务(例如序列标记或问题解答)的输出层,而[CLS]表示则被派送到分类(例如跟随或情绪分析)的输出层。

### 三、视觉特征提取

在计算机视觉领域,特征提取占据了一个关键的位置。三维重构等关键技术其基础都是通过对特征点的图像进行准确的提取与对齐。在计算机视觉学科中,特征提取一直是一个持续发展的研究焦点。简而言之,高效、精确且稳健地提取特征点是完成

高级任务所必需的。在图像中，有些像素的梯度变动很大，例如：角落、边界线等。FAST (Features from Accelerated Segment Test) 是一种快速的角度检测方法。尽管如此，SIFT (Scale-invariant feature transform) 这种尺度不变的特征变换，仍有可能成为最知名的传统局部特征点。这种特征至今仍被应用得非常普遍。通常，特征抽取会经历两个步骤：识别特征点以及进行描述性子计算。描述子计算作为衡量特征相似性的工具，被用于识别在各种图像中所代表的同一个空间实体，例如：BRIEF (Binary Robust Independent Elementary Features) 描述子。

由于视觉信息会比文本信息更丰富，导致处理视觉信息会比较困难，不仅要检测出空间域的对象、前景、物体等元素，还要识别事件域上的运动信息，精准捕捉到对象在不同场景下的变换，然后自适应选择对应的单词和句子结合在一起，由此形成符合人类表达习惯的描述性语言<sup>[84]</sup>。

采用深度学习方法来获得特征点的策略，就是通过使用深度神经网络来获得这些特征，而非人为地去制定这些特征。这种方法的特征识别效果和训练数据以及网络架构有着密切的联系。大部分现有的研究手段都是通过编码-解码器模型来实现视觉特征的编码和解码，从而生成文本描述。举一个视觉数据的示例，包括三个步骤：首先，从图像中提取出特征，然后使用词汇嵌入把这些特性变为一个向量编码，接着把这个视觉特性的向量与一个词汇的向量放在同一个空间里，形成一个视觉特征和单词的一一映射的关系，从而能够准确地获取图像中每一个元素的详细含义。这个视觉编码器能够通过预先训练一个 CNN<sup>[85]</sup> 的图像分类任务来实现。在第二步中，我们采用了一个长短期记忆网络 (LSTM)<sup>[86]</sup> 的长短期记忆网络进行解码。LSTM 网络在进行了训练后，形成了一个基于图像视觉向量的语言模型。此模型借助于循环神经网络，把具有相似编码维度的可变长输入向量，然后运用这个向量进行“解码”，从而获取其最佳的输出结果。在第三步中，根据公式 2-8，我们需要尽可能地提高对图像准确表达的可能性。获取最终的图像描述信息。

$$\theta^* = \arg \max_{\theta} \sum_{(H,T)}^n \log p(T|H; \theta) \quad (2-8)$$

在公式里， $\theta$  是模型的参数， $H$  是一张图像， $T$  是它对应的翻译结果。

视频之所以比文本和图像信息更丰富，是因为视频在二维图像的基础上，增加了音频和时间，同时我们可以获得的视觉信息也更多，因此在选择视觉特征时引入时空注意力机制，以有效区分不同视觉特征的不同维度的重要性程度。

## 本章小结

本章主要介绍了一些相关概念，如话题、镜头、关键帧和语义，为接下来的研究工作打下了坚实的基础。随后，我们将介绍注意力机制的原理、时间注意力和空间注



意力的相关模型，然后引入文本特征提取和视觉特征提取的方法。通过对上述相关技术的研究为本文提出的方法提供了有力的技术支撑。

## 第三章 基于时空注意力关联学习的跨模态话题检测框架

本文提出的时空注意力关联学习的跨模态话题检测整体框架如图 3-1 所示，共分为 5 个步骤：数据预处理、构建时空注意力网络、文本特征提取、构建关联学习网络和热点话题检测。




图 3-1 时空注意力关联学习的跨模态话题检测框架图

首先，对某知名视频网站上的网络视频数据进行数据预处理，再从视频流中提取关键帧、特性和标题等文本信息，时空注意力模型包含三部分：连接网络、空间级注意力和时间级注意力，连接网络是为了更好地指导时空注意力，空间级注意力用于提取帧中的显著区域，时间级注意力用于提取辨别性关键帧；其次，通过 Bert 和 Wide & Deep 获取文本信息的统一表示；然后为不同模态特征分配权重，以捕捉不同模态特征之间的相关性；最后，在对比学习的约束下对特征进行分类来实现热点话题检测。

### 第一节 数据预处理

一旦从主流的视频平台获取了网络视频的数据，我们需要确认视频的上传日期、用于描绘视频的文本内容和视觉内容，接着移除那些在上传时间中遗漏的视频数据，最终，我们会对这些文本和视觉内容各自进行单独的预处理。

#### 一、文本信息预处理

对于海量文本信息，由于某知名视频网站上的视频文本是由普通的作者发布的，而且每个视频的标题和描述都只有十多个字组成，文本内容很少，并且含有大量的重复内容。然而，用户受教育程度、看待事物的角度和用语习惯不同，对于同一视频的文本描述也是不同的，造成了文本数据稀疏，难以实现跨模态之间的关联。为解决上述问题，我们首先对文本进行了标准化处理和汉语分词，并采用了如词干截取和特殊

字符剔除等手段来对文本单词进行剪枝。接着，我们运用 WEKA 来评价每个词的重要性，从而消除文本信息中的噪音。接着，将它们按照降序排列，排除掉尾部权重较低的噪音词和已停用的词。

### （一）规范化处理及分词

为达到文档格式的标准化和一致性，我们必须对它们执行标准化的操作。所有的字母都以小写形式书写，同时在单词和单词之间保持一个空格。中文与日文的单词区别在于它们的句型，然而，对于英文或其它的语言体系，它们则通过使用空格进行单词的区别。因为英文句子中的每一个单词之间都会有空格被划分，所以在执行分词操作的过程中，其复杂性将增加。相比之下，中文语句在表述和构造方面并无明确的分隔标志。借助中文的经典成语、人物、地理位置等，我们运用了最大字符串的计算技术，并且借助基于语义的分词策略，我们能够一并深入探讨语义与句法的关系。这就是我们所说的语义分词策略的核心逻辑框架。这种策略能够借助句子的结构特征和文字的意思，从而解决混淆的问题，并能够精确地区别出具有混淆性的句子。

### （二）去停用词及噪声词

“哎”、“地”、“hi”、“in”、“okay”这些词的使用被视为停用词，因为它们并未对原句的内涵产生任何影响。这种做法有时候也会导致原始文档的识别性下降。筛选出与视频文本内容无关的词汇，不仅能增强文本的表达维度，还能协助后期生成易于识别的文本特征。噪音性的词汇，例如异常数值和特殊字母，会干扰用户对信息的理解。如果这些词汇被引入到文本匹配过程中，不只会减缓匹配的速度，同时也可能对其准确性产生负面影响。因此，我们在本研究中，依据“哈尔滨工业大学”的停用词汇表，智能地剔除了文本信息中的停用词和噪音词。此外，我们还根据具体情况，手动添加一些停用词以减少噪音。

## 二、视觉信息预处理

搜索同一热点话题出来的结果很多都会是重复的视频，并且这些网络视频会用几乎相同的镜头来传达信息。由此可见，关键帧和镜头是热点话题检测任务中的关键信息。相比于静态的文本和图像，视频拥有更丰富的语义信息，而且每个视频时长不统一、视频的画面比例、结构都各式各样。所以在提取视觉特征之前要对视觉信息进行有效地预处理，这样才能更好地挖掘出视觉信息。

### （一）镜头检测

镜头是由一系列连续的图像序列组成的，一般 1 个 2 分钟的视频可以包括 5000 内容，大部分都是反复出现的画面。基于此，本研究通过检测镜头边界，将其划分为更小的单元，以此筛选出重复信息，有效地降低了视频的冗余。主要通过对边界帧的不同性进行识别来进行镜头的边界检查。因为拍摄方式的差异，边界帧的效果也会有所不同。在这其中，镜头的切换有两种形式：渐变（例如淡入、淡出等）和突变（例如硬剪切）。在渐进模型中，其改变的过程相对平稳，而且两帧的相对位置也相对接

近。尽管如此，因为新闻媒体的播放周期限制，其在录像过程中经常使用快速转动的镜头，这种连续两帧的快速转动非常常见，同时两帧的相似性也有着显著的不同。

这篇文章采用了一种基于颜色直方图变化的算法来确定视频的镜头边缘<sup>[87]</sup>。这种方法是通过解析视频文件，产生两幅三维、三通道的图像，然后把这两帧图像的前后两帧保存在新创建的图像中。基于此，我们构建了两个 3D 直方图变量，并对捕获的前后两帧图像进行了相关性的计算。我们已经计算出了前后两帧图像的颜色直方图的分布情况，将前后两帧图像的颜色直方图的均值和的 $1/2$ 作为阈值。最后，我们需要计算出前一帧和后一帧的直方图分布的差异，然后将这个差异与预设的阈值进行对比。如果差异低于预设的阈值，那么就说明这两帧的相似度很高，因此我们可以把它们视为同一个镜头。相反，若差距超出了预设的界限，则下一帧将会被分配至下一个镜头，直至最终一帧的时候，视频才会被完全划分。

## （二）提取关键帧

我们采用了上述的算法，将视频划分为若干个镜头，并在每个镜头中挑选出少数关键帧来展示整个镜头的内容，以此来降低视频场景文字识别所需的帧数。对于提取关键帧，本文使用的方法和<sup>[88]</sup>相同。首要步骤是，从每个镜头的开始、中间以及结束帧中提取数据，然后针对这三个关键帧进行运算，从而生成三个颜色的直方图。接着，我们将中间帧、首帧、尾帧的颜色直方图进行了比较，如果中间帧的颜色直方图与其他两帧的颜色直方图的匹配程度超出了预设的界限，我们就会将首帧和尾帧确定为当前镜头的关键帧，反之，中间帧和首尾帧则会被视为次要帧。终究，依照时间顺序，我们将关键帧分类，以此形成这个视频的关键帧顺序。

## 第二节 构建时空注意力网络

注意力是一种行为和认知过程，它选择性地集中于信息的一个离散方面，无论是主观信息还是客观信息，同时忽略其他可感知的信息。视觉注意力是感知的关键机制之一，它使人类能够有效地选择最有可能感兴趣的视觉数据<sup>[89]</sup>。用于话题检测的注意力模型可以只关注时域中某些帧的相关位置，从而帮助推断视频中发生的动作。在本文中，我们引入了时空注意力，即在时间维度上针对不同帧学习不同的权重，在空间级注意力，必须对具有不同的帧中的显著区域给予关注。如图 3-1 所示，本节将介绍我们提出的时空注意力模型，该模型关键帧输入由三部分组成：连接网络、空间级注意力网络和时间级注意力网络。在空间层面，关键帧中的突出区域会得到强调，而时间层面则会突出具有辨别力的帧。然后，连接网络通过空间-时间注意力学习鉴别性特征。下文将详细介绍上述三个网络。

### 一、连接网络

连接网络基于 ResNet-50<sup>[89]</sup>。ResNet-50 已经被广泛用于各种特征提取中，当深度

学习网络层数越深时，理论上表达能力会更强，但是 CNN 网络达到一定的深度后，再加深，分类性能不会提高，而是会导致网络收敛更缓慢，准确率也随着降低，即使把数据集增大，解决过拟合的问题，分类性能和准确度也不会提高。根据<sup>[90]</sup>的方式，我们已经完成了 ImageNet 的操作。我们从图像或其垂直翻转图像中随机抽取  $64 \times 64$  的裁剪，然后减去每个像素的平均值<sup>[91]</sup>。我们在每次卷积之后以及启动之前，都采用批量归一化（BN）<sup>[92]</sup>。根据<sup>[93]</sup>的步骤，我们首先设定了权重，然后启动了全部的标准/残差网络的训练。学习率自 0.1 起，待误差逐渐平稳时再除以 10，此阶段的模型迭代次数为  $60 \times 104$ 。为了连接空间级和时间级注意力网络，我们做了以下修改。(1) 为了连接空间级注意力网络并指导特征学习，我们用加权池化层取代了 ResNet-50 中的最后一个池化层。这个加权池化层与空间级注意力网络中的 softmax 层相连。因此，空间级注意力可以有效地用于指导特征学习过程。(2) 为了加强联合训练程序，将特征输出层（即加权池化层）作为输入连接到时间级注意力网络。

## 二、空间级注意力

我们可以将一个视频中的关键帧分解为显著区域和非显著区域。显著区域包含与话题相关的可分辨物体和独特运动模式的重要信息。这些区域提供了视觉前景，并提供了与预期语义类别相关的重要信息。我们将周围的区域不重要信息称为“非显著区域”，它们与语义类别的相关性较低。例如，在某知名视频网站上的数据集中“俄罗斯世界杯”这个话题的视频中，显著区域包含球员和踢球的动作，它们表明了“俄罗斯世界杯”这个话题的识别对象和独特的运动模式，而一些新闻转场和背景区域则是与这个话题不太相关的非显著区域。

我们首先利用空间级注意力网络，通过卷积神经网络来提取突出区域，然后提出一种加权集合方法来指导连接网络的学习。因此，连接网络可以利用空间注意力来评估特征。如图 3-1 所示，利用共享卷积层权重的连接网络来构建空间级注意力网络。在共享卷积层之后，还使用了卷积层（CONV）、全局平均池化层（GAP）和 sigmoid 层。每个区域的重要性是通过将 sigmoid 层的权重传播回卷积层来确定的。

形式上，我们可以用  $s_p(a, b)$  来表示给定关键帧的 CONV 层中位于  $(a, b)$  位置的单元  $p$  的激活。然后，对应于某个类别  $c$ ，我们用  $w_p^c$  表示单元  $p$  的权重，用  $z_c$  表示 sigmoid 层的输入。我们可以得到：

$$z_c = \sum_{a,b} \sum_p w_p^c s_p(a, b) = \sum_{a,b} m_c(a, b) \quad (3-1)$$

$$m_c(a, b) = \sum_p w_p^c s_p(a, b) \quad (3-2)$$

其中， $z_c$  表示卷积激活对类别  $c$  的整体重要性；因此， $m_c(a, b)$  可以直接表示空间位置  $(a, b)$  上的激活对类别  $c$  的重要性。与文献<sup>[94]</sup>类似，我们将  $m_c(a, b)$  标准化为与文献<sup>[94]</sup>相同的比例。

$$\tilde{m}_c(a, b) = \frac{g \cdot \exp(m_c(a, b))}{\sum_{x, y} \exp(m_c(a, b))} \quad (3-3)$$

其中,  $g$  是关键帧中各空间网格的数量。

空间级注意力  $\tilde{m}_c$  通过加权池化层被连接网络利用。该层首先将空间级注意力与卷积层相同区域的相关输出相乘。然后, 进行池化操作, 将注意力从空间层转移到连接网络, 并突出具有识别信息的突出区域。

### 三、时间级注意力

对于一个话题的视频序列来说, 每个视频中的不同的帧对于话题检测的贡献是不同的。有些帧包含了一定的判别信息, 在话题检测中起着重要作用。所以我们提出了一种时间级注意力网络来获得用于热点话题检测的判别性帧。图 3-1 展示了由关键帧注意力层和 sigmoid 层组成的时间级注意网络结构。这个网络通过将特征输出层的输出 (也就是加权池化层) 作为输入, 来获取视频序列的时间相关性信息。通过这种方法, 我们实现了对时间级注意力网络的有效学习。




图 3-2 关键帧注意力的框架

如图 3-1 所示, 我们首先把局部特征  $A \in \mathbb{R}^{C \times H \times W}$  发送至卷积层, 从而生成两个新的特征图  $B$  和  $C$ , 然后, 我们把这两个特征图进行了整合, 其中  $\{B, C\} \in \mathbb{R}^{C \times H \times W}$ 。然后我们将它们转化为  $\mathbb{R}^{C \times N}$ , 其中  $N = H \times W$  代表的时像素的总数。然后, 利用 sigmoid 层和矩阵乘法, 我们可以将  $C$  和  $B$  的转置值进行运算, 从而得到空间注意力图  $S \in \mathbb{R}^{N \times N}$ 。

$$k_{ji} = \frac{\exp(B_i \cdot C_j)}{\sum_{i=1}^N \exp(B_i \cdot C_j)} \quad (3-4)$$

其中  $k_{ji}$  表示第  $i$  个位置对第  $j$  个位置的影响,  $B_i$  表示特征图  $B$  第  $i$  个位置,  $C_i$  表示特征图  $C$  第  $j$  个位置。两个特征表示之间的相似度越高, 它们之间的相关性就越大。

在此过程中, 将特征  $A$  加载到卷积层, 那么卷积层就能够产生一个新的特征图  $D \in \mathbb{R}^{C \times H \times W}$  并将其转化为  $\mathbb{R}^{C \times N}$ 。最后, 我们把它与比例参数  $\alpha$  相乘, 然后把特征  $A$  每个元素相加, 从而产生了输出结果  $E \in \mathbb{R}^{C \times H \times W}$ :

$$E_j = \alpha \sum_{i=1}^N \alpha \sum_{i=1}^N (k_{ji} D_i) + A_j \quad (3-5)$$

其中,  $\alpha$  初始化为 0,  $N$  表示像素的数量,  $k_{ji}$  表示第  $i$  个位置对第  $j$  个位置的作用,

$D_i$ 表示特征图 $\mathbf{D}$ 第 $i$ 个位置,  $A_j$ 表示特征 $\mathbf{A}$ 的第 $j$ 个位置。然后逐渐学习分配更多权重<sup>[95]</sup>。根据公式 3-5, 我们能够得知, 在各个位置上的特征 $\mathbf{E}$ 等于所有位置上的特征与最初特征的加权和。因此, 它具有整体的上下文视图, 同时会依照空间注意力图谱有选择地整合上下文。通过相似的语义特征, 我们能够实现互补性, 进一步增强了类内的紧凑度和语义的一致性。

本文根据局部视觉信息进一步挖掘重要的细粒度视觉特征作为局部视觉表示。具体来说, 用框架注意力机制得到每张关键帧的权重。对于一个话题而言, 不是每张关键帧都有用, 所以用适应机制去得到每张图片的一个权重, 然后再做融合。

$q$ 、 $k$ 、 $V$  都是通过全连接神经网络学习得到的, 如公式所示:

$$q=W^q x + b_q \quad (3-6)$$

$$k=W^k x + b_k \quad (3-7)$$

$$V=W^V x + b_V \quad (3-8)$$

每张关键帧的权重如公式 3-9:

$$Img=V_n + \sigma\left(\frac{q_n \cdot k_1}{\sqrt{d}}\right) V_1 + \cdots + \sigma\left(\frac{q_n \cdot k_{n-1}}{\sqrt{d}}\right) V_{n-1} \quad (3-9)$$

其中  $V$  表示经过神经网络映射的单个关键帧的图像特征,  $q$  表示经过神经网络映射的当前时刻的的问询向量,  $k$  表示经过神经网络映射的当前帧数的接收向量,  $d$  表示维度。这里使用到的激活函数为  $\text{sigmoid}$ , 本文将  $\text{softmax}$  函数替换为了  $\text{sigmoid}$ , 公式如 3-6, 因为  $\text{softmax}$  权重最终会归一化到 0-1 之间, 权重总和为 1, 特征之间方差差距大, 导致好的特征被挤占掉, 而  $\text{sigmoid}$  可以保留每一个好的特征作为局部特征。

$$S(x) = \frac{1}{1 + e^{-x}} \quad (3-10)$$

我们采用跨帧连接的方式, 将其他帧的特征融合到当前帧, 如式所示,  $V$  表示经过神经网络映射的单个关键帧的图像特征,  $q$  表示经过神经网络映射的当前时刻的的问询向量,  $k$  表示经过神经网络映射的当前帧数的接收向量。通过问询向量和接收向量点乘可以得到对应帧与当前帧的相对重要性程度, 这样就可以把对话题相关的重要关键帧筛选出来, 更加细粒度的表示可以增强对齐建模。

### 第三节 文本特征提取

我们将文本集数据分为连续型、离散型和长段文本型。如果采用相同的特征提取方式, 比如全部采用全连接神经网络, 会造成数据不均衡。离散型数据维度大, 连续型数据维度小, 容易造成维度间不平衡。所以本文要采用一个既能考虑离散型特征又

能考虑连续型特征的结构 Wide & Deep，采用线性映射得到特征。




图 3-3 Wide & Deep 结构

根据图 3-3 所示，Deep 的输入涵盖了整个数据集，其中包含了标签（Tags）和类别（Category）的信息。这些信息必须通过 Embedding 层的输入连接层，然后组合为 1024 维的 Embedding 向量。之后，它们会逐层通过三层 ReLU 的全连接层，并在 LogLoss 的输出层中完成。Wide 的输入内容主要包括连续性的数据特征，我们选取这些属性的目的在于最大限度地利用 Wide 的“记忆力”。我们的输入层使用训练数据和词汇来创建稀疏和密集特征，并在训练过程中创建标签。标签和类别构成了广度部分。在模型的深层部分，每个类别特征都会生成一个 32 维的嵌入向量。我们将所有的嵌入向量与密集特征相结合，创建一个约 1024 维的输入值。接下来，两个 ReLU 层和逻辑输出单元将接收串联向量。通过小规模随机优化，广义模型和深度感应模型的联合训练能够将输出梯度反向传递到模型的广义部分和深度感应部分。在实验中，模型的广义部分采用了带  $L_1$  正则化的 Follow the Regularized Leader (FTRL) 算法进行优化，而深度部分则采用了 AdaGrad 算法进行优化。该模型的预测结果为

$$P(Y = 1|x) = \sigma(q_{wide}^T[x, \phi(x)] + q_{deep}^T c^{(lf)}) \quad (3-11)$$

其中，Y 是二元类标签， $\sigma(\cdot)$  是 sigmoid 函数， $\phi(x)$  是分布函数，T 是转置。所有宽模态权重向量称为  $q_{wide}$ ， $q_{deep}$  的值用于修改最终激活值  $c^{(lf)}$ 。

对于标题  $s_p$ ，我们首先采用 Bert<sup>[96]</sup> 将每个单词或短语转换为向量表示。如<sup>[96]</sup>中的结果  $H(s_p) = \{s_1, \dots, s_T\}$  所示，其中  $T$  是  $s_p$ ， $s_i \in R^{V \times 1}$  中的单词数， $V$  是所有文本的词汇量。

它被编码为单词的 1-hot 表示（只将一个维度设为 1，其他维度设为 0 的向量），并根据<sup>[96]</sup>得到  $H(s_p) = \{s_1, \dots, s_T\}$ ，其中  $T$  是  $s_p$  中的单词数， $s_i \in R^{V \times 1}$ ， $V$  是所有文本的词汇量。然后，如下所示，我们可以将每个词嵌入一个表示向量中：

$$\hat{s}_i = S_e s_i, S_e \in R^{d_a \times V} \quad (3-12)$$



其中,  $S_e$  表示在网络训练阶段学习到的权重值。我们就得到了具有激活函数  $\tanh$  的文本局部特征:

$$L(t_p) = \{\tanh(\hat{s}_1), \dots, \tanh(\hat{s}_T)\} \quad (3-13)$$

## 第四节 构建关联学习网络

热点话题检测的关键问题之一是如何利用视频中两种模态信息之间的关联性和互补性。我们已经获得了两种模态的特征, 只需对特征进行融合即可得到结果。然而, 文本和关键帧对各种热点话题的贡献是不同的。有些关键帧没有明显的线索, 如风景图片, 应主要从文字说明中识别; 而有些关键帧包含明显的线索, 关键帧线索非常重要。因此, 我们自适应地学习不同模态的特征, 并为多种模态分配不同的权重。

### 一、自适应加权学习

首先, 根据每个图像区域对文本中的所有单词进行细粒度关注, 关注权重由以下公式确定:

$$x_{pq}^{soft} = \frac{\exp(\text{sim}(g_p^i, g_q^l))}{\sum_{j=1}^m \exp(\text{sim}(g_p^i, g_j^l))} \quad (3-14)$$

其中  $\text{sim}(g_p^i, g_q^l)$  表示第  $p$  个图像区域与第  $q$  个单词表示之间的余弦相似度。通过对图像中包含视觉概念的  $n$  个区域进行高置信度编码, 我们可以得到一组局部视觉表征, 记为  $\{g_1^i, \dots, g_n^i\}$ 。我们还对每个句子使用双向 GRU, 以获得句子中  $m$  个单词的局部表示, 表示为  $\{g_1^l, \dots, g_m^l\}$ 。因此, 我们鼓励模型学习这些关键词与图像区域之间的细粒度排列。描述图像区域中相关视觉概念可能性较高的关键词将被分配较大的关注权重。

其次, 利用 CNN 检测到的图像区域的概念标签进行语义引导的硬注意力, 每个图像区域只关注句子中具有相同语义的唯一单词, 具体描述如下:

$$x_{pd}^{hard} = \begin{cases} 1, s.t. & S(g_p^i) == S(g_q^l) \\ 0, & otherwise \end{cases} \quad (3-15)$$

其中,  $S(\cdot)$  代表与句子中特定词语或图像位置相对应的概念。因此, 只有当第  $q$  个词与第  $p$  个图像区域的视觉概念同义或相同时, 才会使用  $a_{pd}^{hard}$ 。

最后, 结合上述两种注意力权重, 可以确定图像和文本之间的精细相似度如下:

$$\text{sim}_g(g, g^t) = \frac{1}{n} \sum_{p=1}^n \frac{1}{m} \sum_{q=1}^m (l_p^{iT} \cdot (x_{pd}^{modal} l_q^l) + g_p^{iT} \cdot (x_{pd}^{multimodal} g_q^l)) \quad (3-16)$$

其中,  $x_{pd}^{modal}$  和  $x_{pd}^{multimodal}$  分别代表细粒度模态注意力权重以及根据短语中第  $q$  个单词和第  $p$  个图像区域计算的多模态注意力权重。为了得到最终的局部相似度, 我们需要估计所有  $n$  个图像区域和  $m$  个关键词的相似度。

表 3-1 自适应加权学习算法的伪代码

---

输入：从 STA 模型提取的特征,  $H^b = [h_1^b, h_2^b, \dots, h_N^b]$  和  $H^n = [h_1^n, h_2^n, \dots, h_N^n]$   
 输出：加权关键帧特征  $H_f^b$  和文本特征  $H_f^n$ 。

---

```

1. def 自适应加权学习( $H^b, H^n$ ):
2.     #步骤 1:设置关键帧特征的优化系数 $Z^b$ ,其中所有 $N$ 个元素初始设置为 $1/N$ 。
3.      $N = \text{len}(H^b)$  #假设 $H^b$ 的长度为  $N$ 
4.      $Z^b = [1/N] * N$ 
5.      $Z^n = [1/N] * N$  #假设 $H^n$ 的长度与 $H^b$ 相同, 初始化 $Z^n$ 
6.     # 重复优化过程直到损失函数收敛
7.     while not 损失函数是否收敛():
8.         #步骤 3:创建单个向量 $O^b$ , 通过组合关键帧特征 $H^b$ 
9.          $O^b = \text{sum}(Z^b[i] * H^b[i] \text{ for } i \text{ in range}(N))$ 
10.        #步骤 4:使用 $O^b$ 来优化特征, 并更新 $Z^n$ 
11.         $Z^n = \text{优化特征}(O^b, H^n)$ 
12.        #步骤 5:创建单个向量 $O^n$ , 通过组合特征 $H^n$ 
13.         $O^n = \text{sum}(Z^n[i] * H^n[i] \text{ for } i \text{ in range}(N))$ 
14.        #步骤 6:使用 $O^n$ 来优化关键帧特征, 并更新 $Z^b$ 
15.         $Z^b = \text{优化关键帧特征}(O^n, H^b)$ 
16.    # 返回优化后的加权关键帧特征和文本特征
17.     $H_f^b = \text{sum}(Z^b[i] * H^b[i] \text{ for } i \text{ in range}(N))$ 
18.     $H_f^n = \text{sum}(Z^n[i] * H^n[i] \text{ for } i \text{ in range}(N))$ 
19.    return  $H_f^b, H_f^n$ 

```

---

## 二、模态融合

跨模态相关性可以捕获不同模态之间的语义交互, 为网络视频热点话题检测提供互补特征, 尤其是当文本和关键帧单独提供给同一话题的预测矛盾时。来自不同模态的特征可能存在巨大的语义差距, 我们需要通过将单模态嵌入转化为共享空间来对齐来自不同模态的特征。为此, 本文设计了跨模态融合对齐模块来学习这种模态相关性。

每个单模态特征在原始特征会经过神经网络映射得到对应模态的特征, 然后在训练过程中, 由于两个模态都是通过同一条特征链路进行计算, 所以迫使特征趋于相同的特征空间, 实现了多个模态对齐的作用。

我们首先测量图像全局表示  $g_i$ 、句子全局表示  $e^t$ 、属性全局表示  $c_k^i$  的成对跨媒体相关性, 旨在利用整个图像和完整句子、属性之间的潜在全局对齐。具体来说, 我们设计了全局对齐的跨媒体联合嵌入损失, 考虑到匹配的视觉文本对和不匹配对的语义相似度之间的差异应该尽可能大。因此, 我们将目标函数定义 3-17 所示:

$$L = \frac{1}{N} \sum_{n=1}^N l_{g_1}(i_n^+, s_n^+, s_n^-) + l_{g_2}(s_n^+, i_n^+, i_n^-) \quad (3-17)$$

等式右边两个变量定义如下：

$$l_{g_1}(i_n^+, s_n^+, s_n^-) = \max(0, \alpha - \text{sim}_g(g_n^{i+}, g_n^{t+})) + \text{sim}_g(g_n^{i+}, g_n^{t-}) \quad (3-18)$$

$$l_{g_1}(s_n^+, i_n^+, i_n^-) = \max(0, \alpha - \text{sim}_g(g_n^{i+}, g_n^{t+})) \text{sim}_g(g_n^{i-}, g_n^{t+}) \quad (3-19)$$

这里的全局对齐与对比学习过程相同。在对比学习中，将当前图像特征和文本特征进行增强定义为正例样本，增强方式是对图像进行一些随机裁剪、随机翻转、对比度曝光度的调整等；当前视频和其他不同类视频的增强为负例样本。其中 $(g_n^{i+}, g_n^{t+})$ 表示匹配的视觉-文本对，为正例，而 $(g_n^{i-}, g_n^{t+})$ 和 $(g_n^{i+}, g_n^{t-})$ 是不匹配的对，为负例。其中 $\text{sim}_g(\cdot)$ 表示成对语义相似度，通过点积计算（这里越大越好）， $\alpha$ 是参数。

我们的目标是在一对图像 $l^i$ 和句子 $l^t$ 中找到文本和视觉图像区域之间的最佳对齐。此外，我们采用自适应对齐策略来充分利用匹配的局部视觉文本块，跨模态相关性可以捕获不同模态之间的语义交互，为网络视频热点话题检测提供互补特征，尤其是当文本和图像单独提供对同一话题的预测矛盾时。来自不同模态的特征可能存在巨大的语义差距，我们需要通过将单模态嵌入转化为共享空间来对齐来自不同模态的特征。为此，布局对齐的目标是实现跨模态对齐来学习这种模态相关性。具体的说，每个单模态特征在原始特征会经过神经网络映射得到对应模态的特征，然后在训练过程中，由于两个模态都是通过同一条特征链路进行计算，所以迫使特征趋于相同的特征空间，实现了多个模态对齐的作用。




图 3-4 跨模态融合对齐模块架构

给定来自跨模态对齐模块的对齐单峰表示 $m_t$ 和 $m_v$ ，本文首先通过计算单峰表示之间的关联权重来获得模态间注意力权重 $InterB$ ，这可以帮助聚合从文本特征到每个视觉的信息特征，反之亦然。在通过特征维度大小对原始特征图进行归一化处理并将其传递给 sigmoid 函数，我们获得权重如下：

$$InterB_{t \leftarrow v} = \text{sigmoid}(f(m^t, m^v)/\text{dim}) \quad (3-20)$$

$$InterB_{v \leftarrow t} = \text{sigmoid}(f(m^v, m^t)/\text{dim}) \quad (3-21)$$

其中 $m^t$ 和 $m^v$ 表示原始单峰嵌入向量， $\text{dim}$ 表示维度，我们通过更新原始单峰嵌入向量得到现在的向量如下：

$$\tilde{m}^t = InterB_{t \leftarrow v} \times m^t \quad (3-22)$$

$$\tilde{m}^v = InterB_{v \leftarrow t} \times m^v \quad (3-23)$$

最后将多模态特征作连接处理作为融合方法<sup>[97][98]</sup>，捕获跨模态的交互。将两个

模态的特征做拼接，然后将拼接好的特征映射到一个权重空间，这里的  $f$  可以采用很多形式，包括 MLP、CNN、ResNet 等，都可以作为模态注意力机制的融合，融合必须要满足两个性质：一是输入特征必须包含多模态的特征，二是输出值为 0-1 之间，代表对应特征的衰减程度，并且保证特征输出的权重总和为 1。本文采用的是 CNN 作为处理函数，考虑到图像特征和视频流特征维度较大，本文采用 CNN 进行降维度处理。两个模态特征融合，融合公式如 3-16 所示：

$$W = f([m_1, m_2]) \quad (3-24)$$

其中  $f$  表示 CNN， $m_1$  表示第一个模态的特征（文本）， $m_2$  表示第二个模态的特征（图片）。然后将得到的两个模态的权重值与原始特征相乘得到新的特征。新特征为如 3-17 所示：

$$\tilde{x} = W[m_1, m_2] \quad (3-25)$$

其中  $W$  表示两个模态的注意力值， $m_1$  表示第一个模态的特征（文本）， $m_2$  表示第二个模态的特征（关键帧）。

本文进一步探索了视觉和文本关系之间的对齐，并且在关系级别对齐中采用自适应对齐策略来匹配视觉和文本之间的关系。首先，我们通过框架注意力机制来筛选关键帧，挖掘图像每一帧之间的关系。然后，我们测试了视觉和文本关系之间的细粒度关系相似度如 3-26 所示：

$$\text{sim}_r(r^t, r_p^{i^T}) = \sum_{j=1}^{m_r} r_p^{i^T} \cdot (a_{pj}^r h_j^r) \quad (3-26)$$

其中  $a_{pj}^r$  是关系级别的注意力权重，类似于局部级别的对齐。 $r^t$  表示句子， $r_i^p$  表示视觉部分。

### 三、对比学习

受<sup>[99]</sup>的启发，本文通过潜在空间中的对比损失，通过最大化同一数据实例的不同增强视图之间的一致性来学习表征。本文在对比学习<sup>[99]</sup>的约束下进行热点话题分类，挖掘特征之间的相似性，从而获得更好的分类结果。将当前关键帧特征和文本特征进行增强定义为正例样本，增强方式对图像进行一些随机裁剪、随机翻转、对比度曝光度的调整等；当前视频和其他不同类视频的增强为负例样本。从而用对比学习挖掘特征之间的相似性，达到一个更好的分类效果。对比学习的目标如 3-27 所示：

$$\text{Score}(f(x), f(x^+)) \gg \text{Score}(f(x), f(x^-)) \quad (3-27)$$

Score 作为一个评估指标，用于衡量样本间的相似度，其中  $x^+$  代表正例样本， $x^-$  代表负例样本。

最终，对比 Loss 如 3-28 所示为：

$$L_N = -E_x \left[ \log \frac{\exp(f(x)^T f(x^+))}{\exp(f(x)^T f(x^+)) + \sum_{j=1}^{N-1} \exp(f(x)^T f(x^-))} \right] \quad (3-28)$$

其中 $x$ 代表原样本， $x^+$ 代表正样本， $x^-$ 代表负样本。其中对应样本有 1 个样本和  $N-1$  个负样本。鉴于对热点话题的探索是一项多样化的分类工作，我们把交叉熵损失函数的含义设置在了公式 3-29 中。

$$L_{cls} = - \sum_{i=0}^{C-1} y_i \log(p_i) = -\log(p_c) \quad (3-29)$$

其中 $p = [p_0, \dots, p_{C-1}]$ 是一个概率分布，每个元素 $p_i$ 表示样本被归类于第 $i$ 类的概率； $y = [y_0, \dots, y_{C-1}]$ 是样本标签的 onehot 表示，当样本属于第 $i$ 个类别时， $y_i = 1$ ，否则 $y_i = 0$ ； $c$ 是样本标签。

接下来，我们讨论了所提方法的优化策略。辅助语义信息正则化任务旨在弥补文本特征和图像特征之间的语义差距，因为本文通过将其损失函数归一化到 $\mu \in (0,1)$ 来限制其效果。通过结合主要分类任务的损失函数，本文最终的损失函数定义如公式 3-30 所示：

$$L_{fin} = L_{cls} + \mu L_{reg} + L_N \quad (3-30)$$

本文的训练是通过梯度下降完成的，训练后，然后在每个 epoch 训练任务，直到损失收敛。

## 第五节 热点话题检测

获得融合特征后，这些特征被用作分类器的输入，以预测每个特征所属的类别。最大分类函数值用于对未识别样本进行分类。在进行训练时，我们会随机挑选 50% 的节点来构建分类器的训练数据。每个训练环节重复十次后，将得出平均分类准确率。辅助语义信息正则化任务旨在弥合文本特征和图像特征之间的语义差距，因为本文将其损失函数归一化为 $\mu \in (0,1)$ 以限制其效果。

我们将第 $a$ 个训练数据在第 $c$ 个类别中的预测得分表示为 $S_a^c = [S_{a,1}^c, S_a^c]^T \in \mathbb{R}^{2 \times k}$ ， $k$ 表示类别的编号， $S_{a,t}^c \in \mathbb{R}^{1 \times k}$ 表示第 $t$ 个模态对第 $a$ 个训练数据在第 $c$ 个类别中的得分。我们将第 $c$ 个类别的融合权重表示为 $W_c = [w_{c,1}, w_{c,2}]$ ，限制条件是 $\sum_{a=1}^2 w_{c,a} = 1, w_{c,a} > 0$ 。每个类别的融合权重都是单独的，为了得到 $W_c$ ，我们将目标函数定义为：

$$\underset{W_c}{\operatorname{argmax}} Q_c - \lambda N_c \quad (3-31)$$

我们将 $Q_c$ 定义为：

$$Q_c = \sum_{a=1}^{n_c} W_c S_a^c T_c \quad (3-32)$$

其中 $n_c$ 表示第 $c$ 个类别中的训练数据数量,  $T_c = [0, \dots, 1, \dots, 0]^T \in \mathbb{R}^{k \times 1}$ , 第 $c$ 个元素是1, 其他元素是0。为了最大化 $Q_c$ 的目标是最大化 $W_c$ 和第 $c$ 列向量 $S_a^c$ 的乘积最大化。同样, 我们将 $N_c$ 定义为

$$N_c = \sum_{\{g=1, g \neq c\}}^k \sum_{a=1}^{n_g} W_c S_a^g T_c \quad (3-33)$$

其中要将 $W_c$ 与 $S_a^g (g \neq c)$ 的第 $c$ 列向量的乘积最小化。 $Q_c$ 和 $N_c$ 要分别考虑 $W_c$ 的正例和负例训练数据的关系,  $\lambda$ 表示平衡正负样本权重的参数, 然后, 我们将 3-34 转换为:

$$\underset{W_c}{\operatorname{argmax}} w_c \left( \sum_{a=1}^{n_c} S_a^c T_c - \lambda \sum_{\{g=1, g \neq c\}}^k \sum_{a=1}^{n_g} S_a^g T_c \right) \quad (3-34)$$

其中 $w_c$ 是第 $c$ 个类别的融合权重,  $S_a^c$ 表示第 $a$ 个训练数据在第 $c$ 个类别中的预测得分,  $\lambda$ 表示平衡正负样本权重的参数,  $k$ 表示类别的编号,  $n_g$ 表示第 $g$ 个类别中的训练数据数量,  $S_a^g$ 表示第 $a$ 个训练数据在第 $g$ 个类别中的预测得分, 融合权重可以通过线性规划学习<sup>[101]</sup>。

对于测试数据, 我们计算并堆叠每个模态的 softmax 最大得分, 定义为 $S_m = [s_{m,1}^T, s_{m,1}^T]^T \in \mathbb{R}^{2 \times k}$ , 分类结果被预测为

$$\underset{a}{\operatorname{argmax}} W_a S_m T_a \quad (3-35)$$

其中 $W_a$ 为第 $a$ 个类别的融合权重,  $S_m$ 为每个模态的最大得分,  $T_a$ 表示第 $a$ 个元素是1, 其他元素是0。

## 本章小结

在此部分中, 本文给出了一个总体的框架, 即通过时空注意力关联学习来进行网络视频热点话题检测。首先提出了一种结合空间注意力和时间注意力的模型, 以提取关键帧和文本的显著特征。其次通过文本特征提取获得属性和标题的统一表示。然后, 为不同模态特征分配权重, 以捕捉不同模态特征之间的相关性。随后, 融合这些特征以获得全局特征, 并通过对比学习强化特征表征。最后通过特征分类来实现热点话题检测。

## 第四章 实验设计与结果分析

### 第一节 实验设置

#### 一、实验环境

在本章中，本文将通过大量的实验对比结果来验证本文提出的基于时空注意力关联学习框架的有效性。如表 4-1 为本文实验的所使用计算机硬件及程序配置环境。

表 4-1 实验环境

| 配置     | 版本                                  |
|--------|-------------------------------------|
| 机器型号   | Dell series microcomputer           |
| 操作系统   | 64 位的 Microsoft Windows 10          |
| CPU    | Intel(R)Core(TM)i7-8550UCPU@2.80GHz |
| 内存     | 16GB                                |
| 硬盘容量   | 512GB 固态硬盘                          |
| 程序代码语言 | Python                              |
| 程序运行环境 | Python3.7                           |
| 机器学习框架 | Pytorch                             |

#### 二、实验数据

5G 的出现为移动互联网的快速进步创造了全新的可能性，使得我们的网络传播效率得以提升，同时也形成了一个低延迟、低能源消耗的网络氛围。用户可以根据自己的喜好随意拍摄、上传视频。与 2D 图像或者单一文本相比，视频提供的信息将更丰富，而短视频的普及则更能体现用户在闲暇碎片时间去浏览热点话题的偏好。本文的数据集主要来源于某知名视频网站上备受关注的 23 个热点话题视频。数据集中包含话题名称、所包含的视频、视频的标题等等。图 4-1 是视觉信息的关键帧数据。



图 4-1 视觉数据示例

在仔细评估了 CNN《时代》和新华社推荐的 2014 年和 2021 年十大新闻主题后，我们选择了 23 个热点话题进行实验。我们将这些热点发布到某知名视频网站，并对相关视频进行爬网，手动选择并确定视频所属的话题。实验数据集的细节如表 4-2 所示，包括 20,533 个网络视频、453,934 个关键帧等等。这些话题涵盖政治、体育、社会、军事、技术、经济、医疗保健等。需要注意的是，有些话题是基于事件的（如 MH370 失踪、日本核事故），而另一些则是周期性的（如 2020 年美国总统大选、钓鱼岛事件）。此外，这些话题的持续时间差异很大。例如，一些话题持续多年（例如乌克兰危机、叙利亚战争），而另一些则很简短（例如马拉多纳去世、2016 年里约奥运会）。我们采用随机抽样的方法，从收集的数据集中获得 70% 的训练集和 30% 的测试集，其中开发集占训练集的 10%。这些因素表明实验数据具有代表性，证实了研究的有效性。



表 4-2 23 个热点话题数据统计

| No | 话题          | #视频数   | #关键帧    | #标签       | 描述<br>/百万 | 评论<br>/百万  | 点赞<br>/百万 | 不喜欢<br>/百万 |
|----|-------------|--------|---------|-----------|-----------|------------|-----------|------------|
| 1  | 俄罗斯世界杯      | 1,065  | 39,069  | 794,411   | 5,666.76  | 126,015.40 | 861.29    | 55.60      |
| 2  | 中美会谈        | 924    | 12,771  | 205,191   | 1,174.44  | 1,339.15   | 17.79     | 1.60       |
| 3  | 叙利亚战争       | 943    | 24,225  | 366,175   | 2,886.90  | 9,557.18   | 149.97    | 10.38      |
| 4  | 阿拉伯之春       | 779    | 14,981  | 209,853   | 1,813.47  | 1,229.35   | 25.42     | 1.60       |
| 5  | 英国脱欧        | 1,075  | 19,359  | 354,661   | 2,204.38  | 4,785.15   | 81.13     | 7.86       |
| 6  | 孟晚舟事件       | 617    | 8,714   | 134,041   | 651.34    | 201.2      | 4.82      | 0.43       |
| 7  | 科比坠机        | 1,013  | 19,495  | 286,532   | 2,079.96  | 21,432.91  | 322.99    | 8.87       |
| 8  | 马拉多纳逝世      | 798    | 17,872  | 274,603   | 1,812.16  | 4,418.32   | 33.22     | 1.80       |
| 9  | 日本核泄漏       | 920    | 18,703  | 375,119   | 2,443.18  | 3,392.23   | 16.7      | 2.46       |
| 10 | 加泰罗尼亚独立     | 916    | 18,244  | 241,091   | 2,102.56  | 813.12     | 16.83     | 1.32       |
| 11 | 香港示威        | 1,043  | 27,585  | 414,674   | 3,109.57  | 5,728.04   | 141.55    | 11.34      |
| 12 | 钓鱼岛事件       | 570    | 13,844  | 278,966   | 1,808.92  | 891.6      | 16.73     | 1.11       |
| 13 | 克里米亚危机      | 621    | 15,170  | 196,832   | 1,970.26  | 5,106.47   | 67.32     | 3.83       |
| 14 | 里约奥运会       | 978    | 28,966  | 634,133   | 4,053.02  | 52,177.47  | 300.11    | 13.69      |
| 15 | 新冠疫情        | 854    | 25,677  | 506,014   | 5,246.53  | 19,009.67  | 340.38    | 22.25      |
| 16 | 土耳其攻打       | 983    | 23,295  | 418,033   | 2,950.82  | 6,022.13   | 82.59     | 11.55      |
| 17 | 马航 mh370 失联 | 898    | 18,787  | 275,880   | 2,373.34  | 6,462.96   | 99.58     | 5.95       |
| 18 | 黄背心         | 925    | 16,658  | 160,983   | 2,091.50  | 1,182.15   | 24.47     | 1.99       |
| 19 | 美国总统选举      | 1,032  | 18,964  | 350,695   | 2,275.56  | 8,457.58   | 140.61    | 15.69      |
| 20 | 伊朗危机        | 916    | 17,283  | 285,116   | 2,059.09  | 3,661.10   | 63.53     | 5.79       |
| 21 | 嫦娥五号        | 883    | 16,308  | 204,050   | 1,781.81  | 472.23     | 15.9      | 0.55       |
| 22 | 乌克兰危机       | 860    | 22,323  | 241,180   | 2,504.02  | 184.38     | 2.01      | 0.17       |
| 23 | 美国次贷危机      | 920    | 15,632  | 794,411   | 2,718.44  | 3,290.93   | 45.13     | 2.36       |
| 总计 |             | 20,533 | 453,934 | 7,411,978 | 55,059.59 | 285,830.62 | 2870.07   | 188.19     |

### 三、实验参数设置

连接网络是基于 ResNet-50 构建的,每列表示具有相同输出大小的各层构建模块。卷积滤波器用 $(W \times H, C)$ 表示,分别代表特征通道的宽度、高度和数量,池化大小用 $(W \times H)$ 表示。对于呈现多个区块的列,括号右侧显示的是堆叠区块的数量。输入大小和输出大小用 $(W \times H \times C)$ 表示。conv1 的帧输入大小为  $64 \times 64 \times 3$ 。加权池化层也是一个特征输出层。空间级注意力网络与从 conv1 层到 conv5\_x 层的连接网络结构相同,并共享这些层的权重。时间级注意力网络由关键帧注意力层和软最大化层组成。关键帧注意力层有 8 层,softmax 层有  $N$  个隐藏单元,其中  $N$  设置为相应数据集中的类别数。为了训练时空注意力模型,我们将输入帧裁剪为  $64 \times 64$  大小。然后,我们使用小批量随机梯度下降法 (SGD) 来优化神经网络。最初,我们将学习率设定为 0.001,在验证准确率达到饱和后,再将学习率降低 10 倍。权重衰减设置为 0.0001,动量设置为 0.9。

## 第二节 评价指标及对比模型

### 一、评价指标

这篇文章通过对标准的精确度(Precision, Pre)、召回度(Recall, Re)以及 F1 值的全方位评价,来验证我们提出的模型在网络视频热门话题检测上的有效性。精确率可以用来衡量预测输出结果的准确性。召回率代表了被预测为正例的数量占实际正例样本总量的百分比。然而准确率和召回率有时会出现冲突的情况。提升精确度可以减少错误的发现,然而这也可能引发更多的遗漏。所以, F1 值是一个被广泛接受的重要评估标准,它既考虑了精度,也兼顾了完整性。公式定义如下:

$$Precision = \frac{|B_i^+|}{A_i} \quad (4-1)$$

$$Recall = \frac{|B_i^+|}{B_i} \quad (4-2)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (4-3)$$

其中  $A_i$  表示被检测到的数据集,  $B_i$  表示与  $A_i$  最匹配的真实受试者数据集,  $B_i^+$  表示正确检测到的受试者数据集, Precision 表示在所有检测到的数据中正确检测到样本的比例, Recall 表示在所有样本中正确检测到样本的比例。F1 是评估实验结果的主要方法,因为它考虑了精确度和召回率的优势。

### 二、对比模型介绍

我们将建议的模型与八种基准方法进行对比,对其进行全面评估,以确保模型的有效性。

CNN<sup>[100]</sup>: 卷积神经网络只将单模态数据作为输入,模型不考虑多模态融合。

**Wide & Deep<sup>[101]</sup>**: 融合了线性模型与深度模型，并且通过训练的模型具备记忆和泛化的能力。

**CBOW<sup>[102]</sup>**: 使用基本的词袋模型，其中每个句子表示为其词嵌入的总和。为每个句子生成一个唯一的向量表示，并将其传递到三层全连接层。

**FND<sup>[103]</sup>**: 通过利用文本与多种视觉线索之间的关系，构建了一个基于多模态不一致性的检测框架，学习特定模态的判别特征，使用改进版的交叉熵损失和对比度损失来探索模态间的不一致性。

**SpotFake+<sup>[104]</sup>**: 我们的多模态技术通过使用迁移学习来收集与之相关的语义和上下文数据，从而提高了检测精度。它的性能超过了单模态模型和多模态模型。

**GLoRIA<sup>[105]</sup>**: 通过比较图像子区域和匹配报告中的单词，基于注意力的框架可以学习全局和局部表征。此外，还提出了利用学习到的表征在各种下游图像识别任务中使用有限标签的方法。

**CoNe<sup>[34]</sup>**: 该方法不仅根据每个样本的类中心对其进行监督，还利用其相似邻近样本的特征作为锚，生成更具适应性和辨别力的目标。

**MMBT<sup>[106]</sup>**: 它通过将关键帧嵌入投影到文本标签空间来连接预训练文本编码器和关键帧编码器。与 Recall 值和 F1 值相比，最大精度值和最小精度值之间的差异最大。最佳精度值为 0.92，最差仅为 0.29。在某些主题中，精确度值和召回率值相差很大，导致 F1 值表现不佳。我们假设，虽然 MMBT 可以通过自我关注使不同模态的信息在不同层面上相互作用，但它没有考虑到来自不同模态的信息的权重问题。

### 第三节 实验结果分析

#### 一、对比实验分析

我们使用各种模型来对数据集做对比实验，具体的结果可以参见表 4-3、表 4-4 所示:

表 4-3 Pre 值对比（每个话题最好的结果加粗）

| 话题 | CNN         | Wide&Deep   | CBOW | SpotFake+   | FND         | GLoRIA      | CoNe | MMBT | Ours        |
|----|-------------|-------------|------|-------------|-------------|-------------|------|------|-------------|
| 1  | 0.67        | 0.72        | 0.81 | 0.81        | 0.73        | 0.82        | 0.40 | 0.29 | <b>0.85</b> |
| 2  | 0.96        | 0.97        | 0.86 | <b>0.98</b> | 0.97        | 0.96        | 0.63 | 0.73 | <b>0.98</b> |
| 3  | 0.73        | 0.77        | 0.81 | 0.85        | 0.78        | 0.76        | 0.55 | 0.86 | <b>0.87</b> |
| 4  | 0.94        | 0.95        | 0.71 | 0.97        | 0.96        | 0.97        | 0.44 | 0.86 | <b>0.98</b> |
| 5  | 0.79        | 0.82        | 0.80 | 0.88        | 0.83        | 0.85        | 0.46 | 0.88 | <b>0.90</b> |
| 6  | 0.82        | 0.85        | 0.80 | 0.90        | 0.85        | 0.82        | 0.22 | 0.39 | <b>0.92</b> |
| 7  | 0.71        | 0.75        | 0.57 | 0.83        | 0.76        | 0.82        | 0.16 | 0.50 | <b>0.86</b> |
| 8  | 0.80        | 0.83        | 0.87 | 0.89        | 0.84        | 0.86        | 0.86 | 0.53 | <b>0.91</b> |
| 9  | 0.96        | 0.97        | 0.81 | <b>0.98</b> | 0.97        | 0.92        | 0.40 | 0.60 | <b>0.98</b> |
| 10 | 0.58        | 0.63        | 0.65 | 0.75        | 0.65        | 0.69        | 0.16 | 0.29 | <b>0.78</b> |
| 11 | 0.88        | 0.90        | 0.92 | 0.94        | 0.90        | 0.89        | 0.62 | 0.72 | <b>0.95</b> |
| 12 | <b>0.99</b> | <b>0.99</b> | 0.58 | <b>0.99</b> | <b>0.99</b> | <b>0.99</b> | 0.34 | 0.39 | <b>0.99</b> |
| 13 | 0.98        | 0.98        | 0.81 | <b>0.99</b> | 0.98        | <b>0.99</b> | 0.63 | 0.74 | <b>0.99</b> |
| 14 | 0.59        | 0.64        | 0.88 | 0.75        | 0.65        | 0.73        | 0.55 | 0.83 | <b>0.90</b> |
| 15 | 0.77        | 0.81        | 0.93 | 0.88        | 0.83        | 0.77        | 0.55 | 0.83 | <b>0.94</b> |
| 16 | 0.87        | 0.89        | 0.85 | 0.93        | 0.90        | <b>0.94</b> | 0.53 | 0.83 | <b>0.94</b> |
| 17 | 0.90        | 0.91        | 0.92 | 0.94        | 0.92        | <b>0.95</b> | 0.38 | 0.59 | <b>0.95</b> |
| 18 | 0.80        | 0.84        | 0.84 | 0.89        | 0.85        | 0.86        | 0.23 | 0.45 | <b>0.91</b> |
| 19 | 0.75        | 0.79        | 0.92 | 0.86        | 0.80        | 0.72        | 0.73 | 0.60 | <b>0.94</b> |
| 20 | 0.86        | 0.88        | 0.92 | 0.93        | 0.89        | 0.93        | 0.61 | 0.76 | <b>0.94</b> |
| 21 | 0.96        | 0.97        | 0.79 | <b>0.98</b> | 0.97        | 0.96        | 0.49 | 0.87 | <b>0.98</b> |
| 22 | 0.71        | 0.76        | 0.86 | 0.84        | 0.76        | 0.85        | 0.37 | 0.78 | <b>0.86</b> |
| 23 | 0.91        | 0.93        | 0.87 | 0.95        | 0.93        | 0.92        | 0.84 | 0.92 | <b>0.96</b> |
| 均值 | 0.82        | 0.85        | 0.82 | 0.90        | 0.86        | 0.87        | 0.48 | 0.67 | <b>0.92</b> |

表 4-4 Re 值对比（每个话题最好的结果加粗）

| 话题 | CNN  | Wide&Deep | CBOW | SpotFake+ | FND  | GLoRIA | CoNe | MMBT | Ours        |
|----|------|-----------|------|-----------|------|--------|------|------|-------------|
| 1  | 0.69 | 0.72      | 0.69 | 0.76      | 0.72 | 0.70   | 0.06 | 0.55 | <b>0.77</b> |
| 2  | 0.85 | 0.88      | 0.90 | 0.93      | 0.88 | 0.93   | 0.81 | 0.57 | <b>0.95</b> |
| 3  | 0.73 | 0.76      | 0.83 | 0.80      | 0.76 | 0.80   | 0.71 | 0.78 | <b>0.81</b> |
| 4  | 0.88 | 0.91      | 0.80 | 0.97      | 0.92 | 0.92   | 0.17 | 0.89 | <b>0.99</b> |
| 5  | 0.83 | 0.86      | 0.91 | 0.92      | 0.87 | 0.89   | 0.30 | 0.90 | <b>0.93</b> |
| 6  | 0.88 | 0.90      | 0.79 | 0.96      | 0.91 | 0.94   | 0.02 | 0.50 | <b>0.98</b> |
| 7  | 0.82 | 0.85      | 0.81 | 0.90      | 0.86 | 0.84   | 0.16 | 0.59 | <b>0.91</b> |
| 8  | 0.77 | 0.80      | 0.76 | 0.84      | 0.80 | 0.82   | 0.47 | 0.65 | <b>0.86</b> |
| 9  | 0.74 | 0.76      | 0.89 | 0.82      | 0.78 | 0.84   | 0.76 | 0.78 | <b>0.90</b> |
| 10 | 0.77 | 0.80      | 0.51 | 0.84      | 0.79 | 0.83   | 0.13 | 0.38 | <b>0.85</b> |
| 11 | 0.83 | 0.86      | 0.88 | 0.92      | 0.87 | 0.90   | 0.54 | 0.76 | <b>0.93</b> |
| 12 | 0.80 | 0.83      | 0.82 | 0.89      | 0.83 | 0.83   | 0.35 | 0.59 | <b>0.90</b> |
| 13 | 0.86 | 0.90      | 0.79 | 0.95      | 0.90 | 0.88   | 0.28 | 0.67 | <b>0.97</b> |
| 14 | 0.85 | 0.88      | 0.83 | 0.93      | 0.88 | 0.89   | 0.75 | 0.78 | <b>0.94</b> |
| 15 | 0.76 | 0.79      | 0.86 | 0.84      | 0.80 | 0.85   | 0.42 | 0.87 | <b>0.88</b> |
| 16 | 0.85 | 0.88      | 0.92 | 0.94      | 0.89 | 0.89   | 0.81 | 0.84 | <b>0.96</b> |
| 17 | 0.86 | 0.90      | 0.81 | 0.95      | 0.90 | 0.92   | 0.42 | 0.69 | <b>0.97</b> |
| 18 | 0.81 | 0.84      | 0.51 | 0.89      | 0.84 | 0.83   | 0.52 | 0.57 | <b>0.90</b> |
| 19 | 0.73 | 0.76      | 0.84 | 0.81      | 0.77 | 0.83   | 0.61 | 0.80 | <b>0.86</b> |
| 20 | 0.85 | 0.89      | 0.80 | 0.94      | 0.89 | 0.89   | 0.19 | 0.66 | <b>0.95</b> |
| 21 | 0.84 | 0.87      | 0.90 | 0.92      | 0.88 | 0.90   | 0.45 | 0.68 | <b>0.94</b> |
| 22 | 0.85 | 0.88      | 0.83 | 0.93      | 0.89 | 0.88   | 0.41 | 0.81 | <b>0.95</b> |
| 23 | 0.89 | 0.92      | 0.88 | 0.98      | 0.94 | 0.96   | 0.83 | 0.93 | <b>0.99</b> |
| 均值 | 0.82 | 0.84      | 0.81 | 0.90      | 0.85 | 0.87   | 0.44 | 0.71 | <b>0.92</b> |

表 4-5 F1 值对比（每个话题最好的结果加粗）

| 话题 | CNN  | Wide&Deep | CBOW | SpotFake+ | FND  | GLoRIA | CoNe | MMBT | Ours        |
|----|------|-----------|------|-----------|------|--------|------|------|-------------|
| 1  | 0.68 | 0.72      | 0.75 | 0.78      | 0.72 | 0.76   | 0.11 | 0.38 | <b>0.80</b> |
| 2  | 0.90 | 0.92      | 0.88 | 0.96      | 0.93 | 0.94   | 0.71 | 0.64 | <b>0.97</b> |
| 3  | 0.73 | 0.76      | 0.82 | 0.82      | 0.77 | 0.78   | 0.62 | 0.82 | <b>0.84</b> |
| 4  | 0.91 | 0.93      | 0.75 | 0.97      | 0.94 | 0.95   | 0.25 | 0.87 | <b>0.98</b> |
| 5  | 0.81 | 0.84      | 0.85 | 0.90      | 0.85 | 0.86   | 0.36 | 0.89 | <b>0.92</b> |
| 6  | 0.85 | 0.88      | 0.79 | 0.93      | 0.88 | 0.87   | 0.04 | 0.44 | <b>0.95</b> |
| 7  | 0.76 | 0.80      | 0.67 | 0.86      | 0.81 | 0.83   | 0.16 | 0.54 | <b>0.88</b> |
| 8  | 0.78 | 0.81      | 0.81 | 0.86      | 0.82 | 0.84   | 0.61 | 0.59 | <b>0.88</b> |
| 9  | 0.84 | 0.85      | 0.85 | 0.89      | 0.87 | 0.88   | 0.53 | 0.68 | <b>0.90</b> |
| 10 | 0.66 | 0.70      | 0.57 | 0.79      | 0.71 | 0.75   | 0.14 | 0.33 | <b>0.82</b> |
| 11 | 0.85 | 0.88      | 0.90 | 0.93      | 0.89 | 0.90   | 0.58 | 0.74 | <b>0.94</b> |
| 12 | 0.88 | 0.90      | 0.68 | 0.94      | 0.90 | 0.90   | 0.35 | 0.47 | <b>0.95</b> |
| 13 | 0.92 | 0.94      | 0.80 | 0.97      | 0.94 | 0.94   | 0.39 | 0.71 | <b>0.98</b> |
| 14 | 0.70 | 0.74      | 0.85 | 0.83      | 0.75 | 0.80   | 0.64 | 0.80 | <b>0.86</b> |
| 15 | 0.77 | 0.80      | 0.89 | 0.86      | 0.81 | 0.81   | 0.37 | 0.85 | <b>0.90</b> |
| 16 | 0.86 | 0.89      | 0.88 | 0.93      | 0.90 | 0.92   | 0.64 | 0.84 | <b>0.95</b> |
| 17 | 0.88 | 0.90      | 0.86 | 0.95      | 0.91 | 0.93   | 0.40 | 0.63 | <b>0.96</b> |
| 18 | 0.80 | 0.84      | 0.63 | 0.89      | 0.85 | 0.84   | 0.32 | 0.50 | <b>0.91</b> |
| 19 | 0.74 | 0.78      | 0.88 | 0.83      | 0.78 | 0.77   | 0.67 | 0.69 | <b>0.89</b> |
| 20 | 0.86 | 0.89      | 0.86 | 0.93      | 0.89 | 0.91   | 0.29 | 0.71 | <b>0.95</b> |
| 21 | 0.90 | 0.91      | 0.84 | 0.95      | 0.92 | 0.93   | 0.47 | 0.76 | <b>0.96</b> |
| 22 | 0.77 | 0.81      | 0.84 | 0.88      | 0.82 | 0.87   | 0.39 | 0.79 | <b>0.90</b> |
| 23 | 0.90 | 0.92      | 0.87 | 0.97      | 0.94 | 0.94   | 0.83 | 0.92 | <b>0.98</b> |
| 均值 | 0.82 | 0.84      | 0.81 | 0.90      | 0.85 | 0.87   | 0.43 | 0.68 | <b>0.92</b> |

我们对 Pre、Re 和 F1 进行了评估，并用粗体标出了表现最好的结果。我们可以从这些表格中推断出分析：

CNN 是一种可以提取局部区域特征的方法，只考虑局部层面。从结果来看，无论是 Pre 还是 Re 还是 F1，CNN 的结果都是最差的，如表 4-3 所示，它的准确率波动最为剧烈，最好的为 0.99，最差的也达到了 0.67。主要原因是它局限于单模态，只考虑视觉局部信息，没有结合时间和空间注意力来捕捉视频中的显著区域和具有辨别性的关键帧。因此，它只考虑了视觉信息，没有实现多模态融合，结果不如其他多模态方法。

Wide & Deep 将文本信息添加到 CNN 中，从而获得新的文本特征，但 Pre、Re 和 F1 均低 SpotFake+和 FND。Wide & Deep 实现了文本信息之间的交互，丰富了文本语义，但它没有考虑视觉判别帧的选择，导致了视觉信息的冗余。这表明，仅有跨模态融合是不够的，选择判别框架和多模态权重学习也很重要。有鉴于此，我们尝试将空间注意力和时间注意力结合起来，捕捉具有辨别力的关键帧和关键区域，并通过权重分配来学习每种模式对不同话题的重要程度。

CBOW 是一种简单的连续词袋模型。每个句子都会生成一个词向量表示，然后传入 MLP。如表 4-5 所示，F1 的跨度很大，某些主题的 F1 最高可达 90%，而最低的

只有 57%。这是因为模型的输入是编码出单词的词包模型，忽略了单词之间的语义关联和句子内部的逻辑关系。检测效果的检测效果并不理想，如“克里米亚危机”和“乌克兰危机”。

FND 学习特定模态的局部判别特征，使用修正版的交叉熵损失和对比度损失来探索模态之间的不一致性，并通过直接连接两种模态的特征来进行模态融合，但不会为多模态特征分配不同的权重。某些主题的 Pre 和 Re 优于 CNN 和 Wide & Deep，这表明以局部级细粒度区块作为整个图片的判别区域，并实现局部级对齐，从而达到了热点话题检测的效果。

SpotFake+是一种多模态方法，其实验结果仅次于本文提出的方法，Pre 值达到 90%。它利用迁移学习捕捉文本和图像之间的语义和上下文信息，简单地实现了文本和图像的融合。但是，它没有考虑为多模态特征分配权重和时空注意力的融合。

GLoRIA 是一种多模态方法，用于开发标签效率高的多模态成像表征，通过比较图像子区域和配对报告中的单词来学习特征，但没有考虑图像特征的判别框架和多模态匹配问题。

CoNe 利用交叉熵损失确保同一类别的样本具有相同的目标。随后，它利用训练特征的邻近臂来构建更精细的目标，以增强一个类别内样本的紧凑性。在这种情况下，视觉特征就失去了适应性，无法捕捉话题类别内的差异。总体而言，其准确性不如其他方法。

如表 4-3、4-4、4-5 所示，MMBT 通过将关键帧嵌入投影到文本标签空间，将预训练文本编码器和关键帧编码器连接起来。与 Re 值和 F1 值相比，最大精度值和最小精度值之间的差异最大。最佳精度值为 0.92，最差精度值仅为 0.29。在某些主题中，精确度值和召回率值相差很大，导致 F1 值表现不佳。我们假设，虽然 MMBT 可使不同模态的信息通过自我关注在不同层面上相互作用，但 MMBT 并未考虑对来自不同模态的特征进行权重分配的问题。

我们的方法取得了更好的结果，最佳 Pre 值达到 0.99，F1 值达到 0.98，Re 值达到 0.99。此外，我们的方法在每个研究对象上的 Pre 值、Re 值和 F1 值都是最稳定的。由此可以得出结论，视觉内容中充满了与热点话题相关的有价值的信息，这些视觉信息是检查与话题相关的测量内容的良好线索。视觉层次和文本层次的精细对齐也进一步提高了准确性。这种方法之所以比其他方法表现出更高的性能，主要原因有以下几点：第一个原因是每个话题的关键帧信息量大，会有很多无用信息和噪声信息。在本文中，我们使用时间空间注意力来过滤关键帧，从而使与话题相关的关键帧获得更高的权重。第二个原因是，我们自适应地为多模态特征分配各种权重，并最终进行融合。在对比学习的约束下，能带来更好的特征分类结果，从而大大提高网络视频热门话题检测的准确率。

总之，Wide & Deep 和 CBOW 只利用了噪声文本信息，因此难以从大规模网络

视频中挖掘话题。CNN 只捕捉关键帧的局部信息作为视觉特征，准确率跨度最大。这种方法无法实现跨模态融合。其他方法同时使用文本和视觉信息。但是，它们无法捕捉具有判别信息的视觉信息，也无法自适应地学习多模态特征权重。通过实验，我们发现所提出的模型能够识捕捉到更多的跨模态相关性，这对于寻找同一时间段的网络视频具有积极的帮助。在本文中，每个主题下的 Pre、Re 和 F1 都超过了其他基准模型，Pre 显著增加。这证明了所获结果的有效性和重要性。

## 二、消融实验分析

通过消融实验，我们研究了注意力分布式关联模型和时空注意力如何与我们建议的方法相互作用。以下是对消融实验结果的分析，如表 4-6 所示。

**Our (AWL)：** 这里只显示了时空注意力模型，去掉了注意力分布式关联模型。我们可以看到，Our(AWL)的平均 *F1* 达到了 88%，甚至优于一些基于多模态的方法。通过比较结果，加入时空注意力模型后，*F1* 可以提高 3%，这说明了分辨框架的有效性。

**Our (S-T)：** 与上述 Our(AWL)不同，这里只显示了注意力分布式关联模型的性能。通过比较结果，我们可以看到，通过自适应地为多种模态分配权重，可以提高 6-7%，这表明了我们提出的跨模态融合方法的有效性。我们提出的跨模态融合方法的有效性。

表 4-6 消融实验结果对比（每个话题最好的结果加粗）

| Topic     | Ours        |             |             | Ours_AWL    |      |      | Ours_S-T    |      |      | Ours_AWL_S-T |      |      |
|-----------|-------------|-------------|-------------|-------------|------|------|-------------|------|------|--------------|------|------|
|           | Pre         | Re          | F1          | Pre         | Re   | F1   | Pre         | Re   | F1   | Pre          | Re   | F1   |
| 1         | <b>0.84</b> | <b>0.77</b> | <b>0.80</b> | 0.77        | 0.74 | 0.76 | 0.74        | 0.72 | 0.73 | 0.72         | 0.72 | 0.72 |
| 2         | <b>0.98</b> | <b>0.95</b> | <b>0.97</b> | <b>0.98</b> | 0.91 | 0.95 | 0.97        | 0.89 | 0.93 | 0.97         | 0.88 | 0.92 |
| 3         | <b>0.87</b> | <b>0.81</b> | <b>0.84</b> | 0.82        | 0.78 | 0.80 | 0.78        | 0.77 | 0.78 | 0.77         | 0.76 | 0.76 |
| 4         | <b>0.98</b> | <b>0.99</b> | <b>0.98</b> | 0.97        | 0.95 | 0.96 | 0.96        | 0.92 | 0.94 | 0.95         | 0.91 | 0.93 |
| 5         | <b>0.90</b> | <b>0.93</b> | <b>0.92</b> | 0.86        | 0.90 | 0.88 | 0.83        | 0.87 | 0.85 | 0.82         | 0.86 | 0.84 |
| 6         | <b>0.92</b> | <b>0.98</b> | <b>0.95</b> | 0.88        | 0.94 | 0.91 | 0.86        | 0.91 | 0.89 | 0.85         | 0.90 | 0.88 |
| 7         | <b>0.86</b> | <b>0.91</b> | <b>0.88</b> | 0.80        | 0.88 | 0.84 | 0.76        | 0.86 | 0.81 | 0.75         | 0.85 | 0.80 |
| 8         | <b>0.91</b> | <b>0.86</b> | <b>0.88</b> | 0.87        | 0.82 | 0.85 | 0.84        | 0.81 | 0.82 | 0.83         | 0.80 | 0.81 |
| 9         | <b>0.98</b> | <b>0.83</b> | <b>0.90</b> | <b>0.98</b> | 0.80 | 0.88 | 0.97        | 0.77 | 0.86 | 0.97         | 0.76 | 0.85 |
| 10        | <b>0.78</b> | <b>0.85</b> | <b>0.82</b> | 0.70        | 0.82 | 0.75 | 0.65        | 0.81 | 0.72 | 0.63         | 0.80 | 0.70 |
| 11        | <b>0.95</b> | <b>0.93</b> | <b>0.94</b> | 0.93        | 0.90 | 0.91 | 0.90        | 0.87 | 0.89 | 0.90         | 0.86 | 0.88 |
| 12        | <b>0.99</b> | <b>0.90</b> | <b>0.95</b> | <b>0.99</b> | 0.87 | 0.93 | <b>0.99</b> | 0.84 | 0.91 | <b>0.99</b>  | 0.83 | 0.90 |
| 13        | <b>0.99</b> | <b>0.97</b> | <b>0.98</b> | 0.98        | 0.92 | 0.95 | 0.98        | 0.91 | 0.94 | 0.98         | 0.90 | 0.94 |
| 14        | <b>0.78</b> | <b>0.94</b> | <b>0.85</b> | 0.70        | 0.91 | 0.79 | 0.66        | 0.89 | 0.75 | 0.64         | 0.88 | 0.74 |
| 15        | <b>0.90</b> | <b>0.85</b> | <b>0.88</b> | 0.85        | 0.82 | 0.84 | 0.82        | 0.80 | 0.81 | 0.81         | 0.79 | 0.80 |
| 16        | <b>0.94</b> | <b>0.96</b> | <b>0.95</b> | 0.91        | 0.91 | 0.91 | 0.90        | 0.89 | 0.90 | 0.89         | 0.88 | 0.89 |
| 17        | <b>0.95</b> | <b>0.97</b> | <b>0.96</b> | 0.93        | 0.93 | 0.93 | 0.92        | 0.91 | 0.91 | 0.91         | 0.90 | 0.90 |
| 18        | <b>0.91</b> | <b>0.90</b> | <b>0.91</b> | 0.87        | 0.87 | 0.87 | 0.85        | 0.85 | 0.85 | 0.84         | 0.84 | 0.84 |
| 19        | <b>0.88</b> | <b>0.82</b> | <b>0.85</b> | 0.83        | 0.79 | 0.81 | 0.80        | 0.77 | 0.79 | 0.79         | 0.76 | 0.78 |
| 20        | <b>0.94</b> | <b>0.95</b> | <b>0.95</b> | 0.91        | 0.92 | 0.91 | 0.89        | 0.90 | 0.89 | 0.88         | 0.89 | 0.89 |
| 21        | <b>0.98</b> | <b>0.94</b> | <b>0.96</b> | <b>0.98</b> | 0.90 | 0.94 | 0.97        | 0.88 | 0.92 | 0.97         | 0.87 | 0.91 |
| 22        | <b>0.86</b> | <b>0.95</b> | <b>0.90</b> | 0.81        | 0.93 | 0.86 | 0.77        | 0.88 | 0.82 | 0.76         | 0.88 | 0.81 |
| 23        | <b>0.96</b> | <b>0.99</b> | <b>0.98</b> | 0.95        | 0.96 | 0.95 | 0.93        | 0.93 | 0.93 | 0.93         | 0.92 | 0.92 |
| Macro Avg | <b>0.92</b> | <b>0.91</b> | <b>0.91</b> | 0.88        | 0.88 | 0.88 | 0.86        | 0.85 | 0.85 | 0.85         | 0.84 | 0.84 |

### 三、示例分析

表 4-7 “俄罗斯世界杯”话题检测示例

|      |                                                                                                                                                       |             |             |             |             |             |             |             |                  |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|------------------|
| 视频序列 |                                                                     |             |             |             |             |             |             |             |                  |
| 标题   | Uruguay and Russia go through - Group A Review!                                                                                                       |             |             |             |             |             |             |             |                  |
| 文本描述 | The reigning champions left it late but Toni Kroos' free-kick deep into injury time secured a memorable victory for Germany against Sweden at Russia. |             |             |             |             |             |             |             |                  |
| 真实标签 | russia world cup                                                                                                                                      |             |             |             |             |             |             |             |                  |
| 模型方法 | CNN                                                                                                                                                   | Wide&Deep   | CBOW        | SpotFake+   | FND         | GloRIA      | CoNe        | MMBT        | 本文               |
| 预测标签 | Rio Olympic                                                                                                                                           | Rio Olympic | Rio Olympic | Rio Olympic | Rio Olympic | Rio Olympic | Rio Olympic | Rio Olympic | Russia World Cup |

表 4-7 给出了话题检测实例以验证本框架的有效性，这是关于“俄罗斯世界杯”话题的例子。由于示例的文字内容和其话题没有明确的语义关联，使得只依赖于单一文本很难准确地识别出视频，从而常常会出现识别失误。而本文的方法通过空间注意力，更强调包含“球员”和“有踢球”的区域，时间注意力对包含球员和踢球动作的关键帧分配了更高的权重，然后通过跨模态关联学习挖掘文本和视觉信息的相关性，生成了 russia、soccer、world cup 等与视频话题密切相关的词汇，以此建立起与话题间的联系，进而准确地被划分。而其他方法是将视频中的关键帧分配相同的权重做处理，然后挖掘文本与视觉的关系，但在热点话题检测的过程中，每一帧对视频识别的贡献是不平等的，而且更应该关注鉴别性帧，才会使话题检测效果良好，这也验证了本文所提出模型的有效性。

### 本章小结

在本章地第一节的内容，我们深入探讨了这次实验的环境以及所采用的数据集，这些数据都是从某知名视频网站获取的，并且已经在众多的学术期刊上得到了大量的应用。这个数据集里面存储了众多关于网络视频的关键帧、标题和标签等信息，这些都是为了检验我们所提出的模型的实际效果。第二节介绍了本文所采用的评价指标及选择一句，然后选择 8 种经典模型进行对比实验，通过对比实验分析、消融实验分析来深入阐述了本文提出的模型优点。



## 第五章 总结与展望

### 第一节 本文总结

随着各大媒体平台的广泛普及,普通用户能随时通过互联网发布自己感兴趣的各式各样的网络资讯。例如,抖音的用户倾向于通过分享短视频来探讨自己的日常琐事和实时热点,而 Twitter 粉丝喜欢用纯文字和拍的日常的画面来分享。因此,跨模态数据传递了不同的信息,其中包含了大量的热点话题。对比于单一模态,跨模态信息包含了受众群图广、用户参与度高的特点。因此,跨模态数据是比单一模态数据所造成的影响大。网络视频包含了文本、图像、音频等信息,是一种典型的多模态数据。互联网的快速发展,网络视频发挥了它独有的优势,现如今已逐渐成为了人们信息交流的主要方式。然而,在面对大量的网络视频的时候,用户需要花费大量时间去搜索相关的视频内容,再经过自己的观点总结,才能初步弄清楚整个热点话题的来龙去脉,而当面对陌生的话题的时候,普通用户就会失去自己的热情和兴趣。由此可见,基于网络视频的热点话题检测研究具有很重大的意义。

互联网视频包含了多种形式的信息,如文本、图像、音频、视频。一方面,多模态数据存在特征空间差异、无法有效整合等问题,使得各种模态数据的空间分布、向量表示的维度和意义各不相同,这使得多模态信息的相似度衡量变得困难,进而影响了对跨模态热点话题的精确检测。另一方面,网络视频中每个视频片段都包含不同的模式。在每种模式中,对象的动作可能只出现在特定的空间区域或特定的时间段,能够捕捉到视频片段中具有鉴别性的帧和区域尤为重要。因此,本文的主要工作总结如下:

本文提出了一种基于时空注意力关联学习的网络视频热点话题检测方法。空间级注意力网络用于说明时空注意力模型中帧的突出区域,而时间级注意力网络则用于利用视频中的判别帧。它们被协同增强和优化,以利用辨别特征。实验结果表明,该模型能明显提高网络视频的话题检测能力。此外,我们还设计了一种新的注意力分布式关联模型,用于从文本和关键帧中提取多模态特征,该模型可自适应地学习每种模态的融合权重,以区分不同模态对热点话题检测的影响并提高分类准确性。在实验过程中,我们将本文与 8 种基线方法进行了比较,从而证实了我们在网络视频话题检测方面的优越性。通过消融实验,我们进一步验证了我们提出的模型的合理性。最后的话题检测结果实例分析,进一步证实了我们提出的方法的有效性。

综上所述,网络视频的话题检测面临巨大挑战,而本文所提出的方法能够有效提高网络视频话题检测的准确性和召回率。所以,本研究能够让众多的网友快速掌握热点话题的来龙去脉,并且能够有力地协助公司进行高效的信息处理,同时也在国家的网络舆论监控方面发挥关键的角色。

## 第二节 未来展望

尽管我们已经对网络视频热点话题检测进行了全面且深度的研究，并且已经获得了相当的成就，但是由于作者的学术能力有所局限，我们还没有在这个领域进行更深层次和更广泛的研究。以下是我们对这篇文章的不足和未来的研究方向的概括：

（1）鉴于这篇论文并没有利用音频数据，我们能够在接下来的探索过程中最大化利用语义图的优秀扩展能力，通过把声音与语义图进行整合，从而增添了语义的多样性，并且提升了模型的稳健性。

（2）由于现有的公开的网络视频主题检索数据库不足，以及数据获取受到的约束，我们的实验都是在一个某知名视频网站上一个数据集上完成的，这使得我们的实验无法做出与各个数据库的横向比较。因此，接下来的研究过程中，我们会向大家展示这篇论文采用的视频数据集，同时也会搜罗来自其它其他知名平台的视频数据集，以验证本研究所提出方法的可移植性。

（3）基于视频中的情感识别。伴随着各种媒体形式的不断涌现，图像、语音等都越来越多地成为人们抒发情感的手段。情感分析或观点挖掘是对人们对产品、服务、个人、问题、话题及其属性的观点、情感、情绪、评价和态度的计算研究。通过对视频中的前后语境来分析说话者的情绪，有利于加强互联网时代的友好交流。

随着越来越多的研究人员对网络视频热点话题检测领域关注度的提升，相信在不久的将来，还会有更多的人也会对网络视频产生更多的兴趣。

## 参考文献

- [1] Peng Y X, Qi J W, Huang X. Current research status and prospects on multimedia content understanding[J]. Journal of Computer Research and Development, 2019, 56(1): 183-208.
- [2] 鲁一杰. 大规模新闻网络视频话题检测与跟踪技术研究[D]. 成都: 西南交通大学, 2012.
- [3] 黄楚新. 全面转型与深度融合:2020 年中国媒体融合发展[J]. 现代传播:中国传媒大学学报, 2021, 43(8): 6.
- [4] 于晗. 传播力蝶变——主流媒体融合转型的破局之路[J]. 群言, 2022(11): 12-15.
- [5] 兰月新,张丽巍,王华伟,等.面向风险监测的网络舆情异常感知与实证研究[J].现代情报, 2022, 42(03):102-108.
- [6] 伊秀娟.基于 LDA 主题模型的高校新闻话题发现研究[D].北京:北京交通大学,2019.
- [7] 周炜翔,张仰森,张良.面向微博热点事件的话题检测及表述方法研究[J].计算机应用研究,2019,36(12):3565-3569+3578.
- [8] Tran D, Bourdev L, Fergus R, et al. Learning spatiotemporal features with 3d convolutional networks[C]//Proceedings of the IEEE international conference on computer vision. 2015: 4489-4497.
- [9] 李博,易东云,赵城利.事件挖掘综述[J].计算机与现代化,2010(11):1-4+8.
- [10] Mohamed D, El-Kilany A, Mokhtar H M O. A Hybrid Model for Documents Representation[J]. International Journal of Advanced Computer Science and Applications, 2021, 12(3).
- [11] Nagarajan G, Minu R I, Jayanthila Devi A. Optimal nonparametric bayesian model-based multimodal BoVW creation using multilayer pLSA[J]. Circuits, Systems, and Signal Processing, 2020, 39(2): 1123-1132.
- [12] Wang F, Xu X, Chen Y, et al. Fuzzy semantics for arbitrary-shaped scene text detection[J]. IEEE Transactions on Image Processing, 2022, 32: 1-12.
- [13] Yu D, Fang A, Xu Z. Topic research in fuzzy domain: Based on LDA topic modelling[J]. Information Sciences, 2023, 648: 119600.
- [14] K. Xiao, Z. Qian, and B. Qin. A graphical decomposition and similarity measurement approach for topic detection from online news[J]. Information Sciences, 2021, 570: 262-277.
- [15] Nandanwar A K, Choudhary J. Semantic features with contextual knowledge-based web page categorization using the GloVe model and stacked BiLSTM[J]. Symmetry, 2021, 13(10): 1772.
- [16] Liu W, Jiang L, Wu Y, et al. Topic detection and tracking based on event ontology[J]. IEEE Access, 2020, 8: 98044-98056.

- [17]O. Jin, N. N. Liu, K. Zhao, et al. Transferring topical knowledge from auxiliary long texts for short text clustering[C]//Proceedings of the 20th ACM international conference on Information and knowledge management. 2011: 775-784.
- [18]Z. Zhao, R. Xiang, and F. Su. Complex event detection via attention-based video representation and classification[J]. Multimedia Tools and Applications, 2018, 77(3): 3209-3227.
- [19]Sun J, Li L, Li W, et al. Enabling 5G: sentimental image dominant graph topic model for cross-modality topic detection[J]. Wireless Networks, 2020, 26: 1549-1561.
- [20]Zhao Zhicheng, Xiang Rui, Su Fei. Complex event detection via attention-based video representation and classification[J]. Multimedia Tools and Applications, 2018, 77(3):3209-3227.
- [21]Peng Y, Zhao Y, Zhang J. Two-stream collaborative learning with spatial-temporal attention for video classification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(3): 773-786.
- [22]Zhang C, Lu S, Zhang C, et al. A novel hot topic detection framework with integration of image and short text information from twitter[J]. IEEE Access, 2018, 7: 9225-9231.
- [23]Li B, Xiao C, Wang L, et al. Dense nested attention network for infrared small target detection[J]. IEEE Transactions on Image Processing, 2022, 32: 1745-1758.
- [24]Dong Y, Liu Q, Du B, et al. Weighted feature fusion of convolutional neural network and graph attention network for hyperspectral image classification[J]. IEEE Transactions on Image Processing, 2022, 31: 1559-1572.
- [25]Zhao S, Gao Y, Ding G, et al. Real-time multimedia social event detection in microblog[J]. IEEE transactions on cybernetics, 2017, 48(11): 3218-3231.
- [26]Kumari K, Singh J P, Dwivedi Y K, et al. Multi-modal aggression identification using convolutional neural network and binary particle swarm optimization[J]. Future Generation Computer Systems, 2021, 118: 187-197.
- [27]Thyagarajan K K, Kalaiarasi G. A review on near-duplicate detection of images using computer vision techniques[J]. Archives of Computational Methods in Engineering, 2021, 28(3): 897-916.
- [28]Zhang C, Liu D, Wu X, et al. Near-duplicate segments based news web video event mining[J]. Signal Processing, 2016, 120: 26-35.
- [29]Zhou L, Mao Y, Xiong N, et al. BTD: An effective business-related hot topic detection scheme in professional social networks[J]. Information Sciences, 2023, 630: 420-442.
- [30]Zhang C, Liu G, Xiao X. Cross-media correlation learning for web video event mining with integrated text semantics and network structural information[J]. Neural Computing and Applications, 2023, 35(16): 11815-11831.
- [31]Zhang C, Lei Y, Xiao X, et al. Cross-media video event mining based on attention graph structure learning[J]. Neurocomputing, 2022, 502: 148-158.
- [32]张承德,刘雨宣,肖霞,等.跨媒体语义关联增强的网络视频热点话题检测[J].计算机

- 研究与发展, 2023, 60(11):2624-2637.DOI:10.7544/issn1000-1239.202220560.
- [33]Wang X, Zhu L, Yang Y. T2vlad: global-local sequence alignment for text-video retrieval[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 5079-5088.
- [34]M. Zheng, S. You, L. Huang, X. Su, F. Wang, C. Qian, X. Wang, and C. Xu, "Cone: Contrast your neighbours for supervised image classification," arXiv preprint arXiv:2308.10761,2023, 2023.
- [35]Laptev I. On space-time interest points[J]. International journal of computer vision, 2005, 64: 107-123.
- [36]Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
- [37]Dalal N, Triggs B, Schmid C. Human detection using oriented histograms of flow and appearance[C]//Computer Vision–ECCV 2006: 9th European Conference on Computer Vision, Graz, Austria, May 7-13, 2006. Proceedings, Part II 9. Springer Berlin Heidelberg, 2006: 428-441.
- [38]Wang H, Schmid C. Action recognition with improved trajectories[C]//Proceedings of the IEEE international conference on computer vision. 2013: 3551-3558.
- [39]Xian Y, Rong X, Yang X, et al. Evaluation of low-level features for real-world surveillance event detection[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2016, 27(3): 624-634.
- [40]Wang L M, Qiao Y, Tang X. Mining motion atoms and phrases for complex action recognition[C]//Proceedings of the IEEE international conference on computer vision. 2013: 2680-2687.
- [41]Liu J, Kuipers B, Savarese S. Recognizing human actions by attributes[C]//CVPR 2011. IEEE, 2011: 3337-3344.
- [42]Wang L M, Qiao Y, Tang X. Motionlets: Mid-level 3d parts for human motion recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2013: 2674-2681.
- [43]Fradet H, Luvison B, Pham Q C. Crowd behavior analysis using local mid-level visual descriptors[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2016, 27(3): 589-602.
- [44]Izadinia H, Shah M. Recognizing complex events using large margin joint low-level event model[C]//Computer Vision–ECCV 2012: 12th European Conference on Computer Vision, Florence, Italy, October 7-13, 2012, Proceedings, Part IV 12. Springer Berlin Heidelberg, 2012: 430-444.
- [45]Sun C, Nevatia R. Active: Activity concept transitions in video event classification[C]//Proceedings of the IEEE international conference on computer vision. 2013: 913-920.

- [46] Fradi H, Luvison B, Pham Q C. Crowd behavior analysis using local mid-level visual descriptors[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2016, 27(3): 589-602.
- [47] Zhang Y, Qin L, Ji R, et al. Exploring coherent motion patterns via structured trajectory learning for crowd mood modeling[J]. IEEE Transactions on Circuits and Systems for Video technology, 2016, 27(3): 635-648.
- [48] Wu Z, Jiang Y G, Wang X, et al. Multi-stream multi-class fusion of deep networks for video classification[C]//Proceedings of the 24th ACM international conference on Multimedia. 2016: 791-800.
- [49] Xie G S, Zhang X Y, Yan S, et al. Hybrid CNN and dictionary-based models for scene recognition and domain adaptation[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2015, 27(6): 1263-1274.
- [50] Ji S, Xu W, Yang M, et al. 3D convolutional neural networks for human action recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(1): 221-231.
- [51] Yue-Hei Ng J, Hausknecht M, Vijayanarasimhan S, et al. Beyond short snippets: Deep networks for video classification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 4694-4702.
- [52] Wang L, et al. Temporal segment networks: Towards good practices for deep action recognition[C]//European conference on computer vision. Springer, Cham, 2016: 20-36.
- [53] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [54] Wu Z, Wang X, Jiang Y G, et al. Modeling spatial-temporal clues in a hybrid deep learning framework for video classification[C]//Proceedings of the 23rd ACM international conference on Multimedia. 2015: 461-470.
- [55] Yan X, Chang H, Shan S, et al. Modeling video dynamics with deep dynencoder[C]//Computer Vision—ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13. Springer International Publishing, 2014: 215-230.
- [56] Srivastava N, Mansimov E, Salakhudinov R. Unsupervised learning of video representations using lstms[C]//International conference on machine learning. PMLR, 2015: 843-852.
- [57] Wang X, Farhadi A, Gupta A. Actions~ transformations[C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2016: 2658-2667.
- [58] Goroshin R, Bruna J, Tompson J, et al. Unsupervised learning of spatiotemporally coherent metrics[C]//Proceedings of the IEEE international conference on computer vision. 2015: 4086-4093.
- [59] Wei Y, Zhao Y, Lu C, et al. Cross-modal retrieval with CNN visual features: A new baseline[J]. IEEE transactions on cybernetics, 2016, 47(2): 449-460.
- [60] Mnih V, Heess N, Graves A. Recurrent models of visual attention[J]. Advances in neural

- information processing systems, 2014, 27.
- [61] Liu D, Greene D, Dong R. A novel perspective to look at attention: Bi-level attention-based explainable topic modeling for news classification[J]. arXiv preprint arXiv:2203.07216, 2022.
- [62] Zhang J, Liu Y, Li R C, et al. End-to-end spatial attention network with feature mimicking for head detection[C]//2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020). IEEE, 2020: 199-206.
- [63] Zhu M, Jiao L, Liu F, et al. Residual spectral-spatial attention network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(1): 449-462.
- [64] Sun Y, Malihi S, Li H, et al. Deepwindows: Windows instance segmentation through an improved mask R-CNN using spatial attention and relation modules[J]. ISPRS International Journal of Geo-Information, 2022, 11(3): 162.
- [65] Xin D, Chen Y W, Li J. Fine-grained butterfly classification in ecological images using squeeze-and-excitation and spatial attention modules[J]. Applied Sciences, 2020, 10(5): 1681.
- [66] Karpathy A, Toderici G, Shetty S, et al. Large-scale video classification with convolutional neural networks[C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2014: 1725-1732.
- [67] Guo S, Lin Y, Feng N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 922-929.
- [68] Zhao Z, Elgammal A M. Information Theoretic Key Frame Selection for Action Recognition[C]//BMVC. 2008: 1-10.
- [69] Yan C, Tu Y, Wang X, et al. STAT: Spatial-temporal attention mechanism for video captioning[J]. IEEE transactions on multimedia, 2019, 22(1): 229-241.
- [70] Denison R N, Carrasco M, Heeger D J. A dynamic normalization model of temporal attention[J]. Nature human behaviour, 2021, 5(12): 1674-1685.
- [71] Wharton Z, Behera A, Liu Y, et al. Coarse temporal attention network (cta-net) for driver's activity recognition[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 1279-1289.
- [72] Fan C, Zhang Y, Pan Y, et al. Multi-horizon time series forecasting with temporal attention learning[C]//Proceedings of the 25th ACM SIGKDD International conference on knowledge discovery & data mining. 2019: 2527-2535.
- [73] Qiang S U N, Shuyu W. Self-supervised Multimodal Emotion Recognition Combining Temporal Attention Mechanism and Unimodal Label Automatic Generation Strategy[J]. 电子与信息学报, 2024, 46(2): 588-601.
- [74] Liu L, Shao L, Rockett P. Boosted key-frame selection and correlated pyramidal motion-feature representation for human action recognition[J]. Pattern recognition, 2013, 46(7):

- 1810-1818.
- [75] Xu W, Miao Z, Zhang X P, et al. A hierarchical spatio-temporal model for human activity recognition[J]. IEEE Transactions on Multimedia, 2017, 19(7): 1494-1509.
- [76] Tian C, Xu Y, Zuo W, et al. Designing and training of a dual CNN for image denoising[J]. Knowledge-Based Systems, 2021, 226: 106949.
- [77] 洪宇, 张宇, 刘挺, 李生. 话题检测与跟踪的评测及研究综述[J]. 中文信息学报, 2007(06): 71-87.
- [78] Boecking B, Usuyama N, Bannur S, et al. Making the most of text semantics to improve biomedical vision-language processing[C]//Computer Vision-ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23-27, 2022, Proceedings, Part XXXVI. Cham: Springer Nature Switzerland, 2022: 1-21.
- [79] 石磊, 王毅, 成颖, 魏瑞斌. 自然语言处理中的注意力机制研究综述[J]. 数据分析与知识发现, 2020, 4(05): 1-14.
- [80] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [81] Gehrmann S, Strobel H, Rush A M. Gltr: Statistical detection and visualization of generated text[J]. arXiv preprint arXiv:1906.04043, 2019.
- [82] Liu Z, Wang L, Wu W, et al. Tam: Temporal adaptive module for video recognition[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 13708-13718.
- [83] 张千, 王庆玮, 张悦, 等. 基于深度学习的文本特征提取研究综述[J]. 计算机技术与发展, 2019, 29(12): 61-65.
- [84] Kojima A, Izumi M, Tamura T, et al. Generating natural language description of human behavior from video images[C]//Proc of the 15th Int Conf on Pattern Recognition. Piscataway, NJ: IEEE, 2000: 728-731.
- [85] Kim S. A Beginner's Guide to Convolutional Neural Networks (CNNs)[J]. towards data science, 2019, 32(10): 2196-2202.
- [86] Sundermeyer M, Schlüter R, Ney H. LSTM neural networks for language modeling[C]//Thirteenth annual conference of the international speech communication association. 2012.
- [87] Mas J, Fernandez G. Video Shot Boundary Detection Based on Color Histogram[C]//TRECVID. 2003.
- [88] Xie L, Natsev A, Kender J R, et al. Visual memes in social media: tracking real-world news in YouTube videos[C]// Proceedings of the 19th International Conference on Multimedia 2011, Scottsdale, AZ, USA, November 28 - December 1, 2011. 2011.
- [89] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [90] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image



- Recognition[J].Computer Science, 2014.DOI:10.48550/arXiv.1409.1556.
- [91]Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [92]Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [93]He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.
- [94]Diba A, Fayyaz M, Sharma V, et al. Spatio-temporal channel correlation networks for action classification[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 284-299.
- [95]He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.
- [96]Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [97]Fu X, Li J, Yang K, et al. Dynamic online HDP model for discovering evolutionary topics from Chinese social texts[J]. Neurocomputing, 2016, 171: 412-424.
- [98]Teh Y, Jordan M, Beal M, et al. Sharing clusters among related groups: Hierarchical Dirichlet processes[J]. Advances in neural information processing systems, 2004, 17.
- [99]Wu Y, Xie R, Zhu Y, et al. Multi-view multi-behavior contrastive learning in recommendation[C]//International conference on database systems for advanced applications. Cham: Springer International Publishing, 2022: 166-182.
- [100] Staykovski T, Barrón-Cedeno A, Da San Martino G, et al. Dense vs. sparse representations for news stream clustering[C]//CEUR WORKSHOP PROCEEDINGS. CEUR-WS, 2019, 2342: 47-52.
- [101] Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st workshop on deep learning for recommender systems. 2016: 7-10.
- [102] Chinniyan K, Gangadharan S, Sabanaikam K. Semantic Similarity based Web Document Classification Using Support Vector Machine[J]. International Arab Journal of Information Technology (IAJIT), 2017, 14(3).
- [103] Singhal S, Dhawan M, Shah R R, et al. Inter-modality discordance for multimodal fake news detection[C]//Proceedings of the 3rd ACM International Conference on Multimedia in Asia. 2021: 1-7.
- [104] Singhal S, Kabra A, Sharma M, et al. Spotfake+: A multimodal framework for fake news detection via transfer learning (student abstract)[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(10): 13915-13916.

- [105] Huang S C, Shen L, Lungren M P, et al. Gloria: A multimodal global-local representation learning framework for label-efficient medical image recognition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3942-3951.
- [106] Kiela D, Bhooshan S, Firooz H, et al. Supervised multimodal bitransformers for classifying images and text[J]. arXiv preprint arXiv:1909.02950, 2019.

## 在读期间科研成果

[1] Cross-modal Associated Learning with Spatial-Temporal Attention for Hot Topic Detection [J]. Knowledge and Information Systems. (已投稿, 审稿中)

## 在读期间参与的科研项目

- 中央高校基本科研业务费专项资金 (202211405)

## 致谢

三年千日，聚散有时。须臾之间，我的研究生生涯也即将结束，终将告别我 23 岁到 25 岁的青春岁月。这三年装着我 23 岁时科研与课程同步进行的求学时光，24 岁时埋头于实验室度过的紧张又充实的科研生活，25 岁面向社会锤炼坚强的心脏和扎实的本领。这段弥足珍贵又匆匆飞逝的三年让我收获了不同的感悟和成长，在此借此篇致谢感恩一路陪我同行的你们！

首先，我要感谢我的导师张承德老师。老师在科研上严谨治学、一丝不苟的态度潜移默化地影响着团队的每一个人。桃李不言，下自成蹊。研究过程中您字斟句酌、反复批阅、耐心教导、倾囊相授才使得我能够产出科研成果。在这三年的求学路上，不论是传道授业，还是生活中的琐碎小事，都要感谢您的教诲与包容。真切祝愿老师您未来平安顺遂、青春常在。

其次，我要感谢我的家人。我的爸爸不善言辞、朴素节俭，却能够将那把给我遮风挡雨的伞撑的很稳，让我安心的学习，您永远是我面向社会披荆斩棘的底气！我的妈妈真诚正直、勤劳勇敢，在她的碎碎念念中我度过了无忧无虑的岁岁年年。还有我的老妹虽然看似没心没肺，但你大大咧咧、嘻嘻哈哈的性格却是我们一家人的开心果，你一定要永远乐观开怀、肆意自在。因为有你们在，我才会时常于千里之外的武汉时刻心系家乡。希望时光能够走的慢一点，希望在我事业步入正轨之时能够赶在父母变老之前！

此外，还要感谢与我一路同行的室友、同门以及朋友。山水一程，何其有幸。想念那些在课堂进行小组讨论、在实验室进行科研探讨的日子。感谢我的朋友们让我成为更加自信更加丰富的自己。求学的时光总是过的很快，正是有你们的温暖和陪伴，我对这段匆忙又充实的求学旅程才会如此热爱与不舍。祝愿你们的未来前程似锦、心想事成。

然后，我要感谢仰望星空且脚踏实地的自己。科研之路每一次突破都是在无数个日夜的冥思苦想之后，感谢自己没有放弃，也好在没有放弃！前路漫漫亦灿灿，希望未来我能继续一如既往地全力以赴、逐梦前行。

最后，在此衷心感谢所有为论文评审工作辛苦付出的老师和专家，谢谢你们在百忙之中耗费宝贵的时间耐心批阅我的论文。